Fase 3 — documentos

download

apenas o primeiro documento (only_first_doc)

parse

PDF/HTML → text.txt

anonymize

PII → marcadores — braço exp-anon

evaluate

LLM: tópico + resumo → :Documento.topic (sincroniza disco↔grafo)

keywords

vocabulário controlado crescente · 2.973 termos, 517 com df≥3

artifacts/cache — doc_embeddings · topic_embeddings · keywords_by_processo

caches em disco garantem features reprodutíveis entre braços