Modelagem de tipos de processo administrativo e de caminhos típicos a partir de registros de atividades

um catálogo auditável para a transparência e otimização administrativa

Gabriel Feitosa Melo Coelho[1]
Prof. Dr. Dimmy Karson Soares Magalhães[2]

Resumo:
Embora a legislação de transparência exija o mapeamento de procedimentos administrativos, sistemas como o Sistema Eletrônico de Informações (SEI) registram ações isoladas sem consolidar o fluxo real dos processos. O problema desta pesquisa consiste em determinar se é possível extrair, a partir de registros transacionais brutos, um catálogo auditável e confiável dos procedimentos efetivamente executados. Trata-se de uma pesquisa aplicada e quantitativa, conduzida como estudo de caso na Secretaria de Administração do Estado do Piauí (SEAD-PI), analisando 5.243 processos concluídos em 2025. Propõe-se um *pipeline* que modela os eventos como um grafo de conhecimento e agrupa os processos combinando o texto do documento inicial ao histórico de tramitação. Para predizer o caminho típico de cada processo, avaliaram-se seis famílias de modelos (incluindo cadeias de Markov e arquiteturas GRU), testadas em três alfabetos de traço: ação por unidade, roteamento e procedimento. Os resultados mostram ganhos preditivos consistentes contra partições-controle embaralhadas em todas as 252 comparações. Comparado a um modelo global, obteve-se ganho preditivo significativo apenas no alfabeto de procedimento (0,109 com Markov de terceira ordem e 0,131 com GRU). As métricas internas de clusterização não apontaram um agrupamento único ideal. Contudo, a aplicação das técnicas gerou um catálogo validado de 60 tipos de processos, com 75,1% de cobertura no alfabeto de roteamento, atendendo aos requisitos estritos de anonimização. Conclui-se que o uso de inteligência artificial sobre *logs* administrativos supre a lacuna empírica dos sistemas, viabilizando a governança orientada a dados.

Palavras-chave: *mineração de processos; inteligência artificial; redes neurais; otimização; transparência administrativa*.

Abstract:
Access-to-information laws presume the existence of consolidated records for administrative procedures, which often are never created. This research investigates whether an auditable

[1]Graduando em Engenharia de Software pelo Instituto de Ensino Superior iCEV. E-mail: gabrielcoelho09gc@gmail.com.
[2]Orientador. Doutor. Docente do curso de Engenharia de Software do Instituto de Ensino Superior iCEV. Email:

catalogue of executed process types and their typical paths can be derived directly from raw event logs. We conducted an applied, quantitative single-case study at the Secretariat of Administration of the State of Piaui, analyzing 5,243 concluded cases from the Electronic Information System (SEI) in 2025. The methodology builds an event knowledge graph, clusters cases by combining opening-document text with routing and action history, and fits typical paths using six model families across three trace alphabets (action-by-unit, routing, and procedure). Results show positive predictive gains over shuffled control partitions in all 252 baseline comparisons. Compared to a single global model, predictive gains were significant only in the procedure alphabet (0.109 for a third-order Markov chain; 0.131 for GRU); in action-by-unit and routing, gains were indistinguishable from residuals. Although accuracy separated the 14 candidate clusterings by only 0.0055 and internal indices did not reliably predict downstream quality, the pipeline successfully delivered a catalogue of 60 process types with 0.751 coverage in the routing alphabet. Furthermore, the required automated anonymization proved non-inferior at the pre-registered margin across all 54 comparisons.

Keywords: *process mining; clustering; graphs; administrative transparency*.

1 INTRODUÇÃO

O direito de acesso à informação pressupõe que a administração pública conheça os seus próprios fluxos de trabalho. Regimes de transparência ativa e mandatos de dados abertos frequentemente operam sob a premissa de que os relatos da prática administrativa já existem e aguardam apenas publicação. Contudo, Brauneis e Goodman (2018) testaram esse pressuposto empiricamente e constataram que o maior obstáculo à transparência não é o sigilo, mas a inexistência prévia desses registros consolidados.

Os sistemas eletrônicos de processo administrativo mitigam parcialmente esse problema. O Sistema Eletrônico de Informações (SEI), por exemplo, registra eventos atômicos para cada processo, como a unidade recebedora e a ação executada. Embora o rastro transacional exista, falta a consolidação que traduza esses dados agregados em conhecimento útil sobre quais procedimentos a administração de fato executa e como tramitam. As administrações mantêm uma taxonomia oficial de tipos de processo, mas esta é aplicada manualmente no momento da abertura do caso. Consequentemente, a sua precisão em relação à prática efetiva é uma questão empírica.

Há uma limitação técnica no SEI que inviabiliza presumir a validade dessa taxonomia: o sistema não impõe restrições de sequência de atividades por tipo de processo. Dois casos de um mesmo tipo declarado podem seguir fluxos inteiramente distintos. Por essa razão, a taxonomia oficial entra neste trabalho como uma hipótese a ser testada, exigindo que o catálogo de processos seja derivado diretamente dos registros transacionais (Seção 2.2.7).

No ordenamento brasileiro, a relevância dessa derivação é acentuada pelo dever legal de publicar as principais etapas de cada procedimento em formato legível por máquina. A discussão sobre o alcance material desse dever sobre o corpus estudado é aprofundada na Seção 2.2.5.

A motivação desta pesquisa advém de um contexto prático. Atuo como analista de dados da Secretaria de Administração do Estado do Piauí (SEAD-PI) e sou graduando em Engenharia de Software pelo iCEV. No exercício dessa função, observei a referida assimetria entre o volume de registros gerados no SEI e a ausência de mapeamentos estruturados. Dado que o estudo analisa a organização à qual estou vinculado, com acesso funcional aos dados, faz-se necessária a declaração de potencial conflito de interesses. Para mitigar vieses e garantir o rigor metodológico, adotaram-se três providências: (i) a pesquisa é regida por um instrumento jurídico formal da SEAD-PI que impõe a anonimização dos dados (PIAUÍ. Secretaria de Administração do Estado do Piauí, 2026); (ii) todos os resultados são regerados de forma automatizada por um *pipeline* versionado; e (iii) as limitações do estudo estão explicitamente mapeadas na Seção 4.11. A SEAD-PI também reteve o direito de aprovação prévia sobre a divulgação dos resultados (Seção 3.1).

O objeto da pesquisa é a extração dos tipos de processo administrativo e de seus respectivos caminhos típicos, derivados dos registros do SEI, totalizando 5.243 processos concluídos em 2025. O estudo foca no mapeamento da forma e fluxo dos procedimentos, excluindo expressa-

mente a análise de mérito das decisões administrativas ou do desempenho de servidores.

O problema de pesquisa formulado é: *é possível derivar dos próprios registros de atividades da administração um catálogo auditável dos tipos de processo efetivamente executados e de seus caminhos típicos, e sob qual evidência este catálogo pode ser considerado confiável?*

Para responder a essa pergunta, formulam-se três hipóteses, que serão testadas e avaliadas com base nas evidências da Seção 4 e retomadas na Seção 5:

H1 O agrupamento emergente, derivado da vetorização do documento inicial combinada ao histórico de tramitação, capta estruturas reais do acervo não contempladas pela taxonomia declarada. A hipótese será refutada se uma partição-controle embaralhada obtiver desempenho a jusante equivalente, ou se a redundância com a taxonomia oficial for substancial.

H2 A escolha do algoritmo de agrupamento e o uso de índices internos de validade são suficientes para selecionar a melhor partição a ser publicada. A hipótese será refutada se as métricas não conseguirem separar algoritmos distintos quanto à utilidade a jusante, ou se os índices internos apresentarem baixa correlação com a qualidade final.

H3 Modelar o caminho típico especializado por tipo de processo melhora a predição da próxima atividade em comparação a um modelo global único treinado sobre o corpus inteiro. A hipótese será refutada se o ganho preditivo desaparecer ou for negativo na comparação direta entre modelos da mesma família.

O objetivo geral é produzir e validar um catálogo auditável dos tipos de processo administrativo da SEAD-PI e de seus caminhos típicos, visando instrumentalizar a transparência ativa. São objetivos específicos:

a) Construir um grafo de conhecimento de eventos a partir dos *logs* do SEI e derivar tipos de processo emergentes;

b) Verificar se os agrupamentos capturam estruturas latentes não registradas pela taxonomia oficial;

c) Avaliar se os índices internos de validade e algoritmos de agrupamento conseguem isolar partições candidatas;

d) Treinar e avaliar modelos de caminhos típicos comparando-os contra três controles: sucessor mais frequente, modelo global único e partição embaralhada, incluindo avaliação qualitativa sobre um processo real;

e) Quantificar o impacto preditivo decorrente do requisito de anonimização;

f) Selecionar a configuração ideal de partição, alfabeto de traço e arquitetura de modelo para o catálogo final.

A justificativa técnica e teórica do trabalho baseia-se em duas contribuições. A primeira é a entrega de um artefato reprodutível: um catálogo empírico validado, demandado pela literatura de auditoria do setor público (AALST et al., 2010; NAI et al., 2026; ARAUJO et al., 2023; LIMA E SILVA et al., 2026). A segunda contribuição é o protocolo de avaliação externa. A confiabilidade do artefato gerado fundamenta-se nos controles rigorosos adotados na Seção 3.7. O uso de partições embaralhadas e *baselines* fixas delimita as afirmações do método, evitando o viés de confirmação e atestando que os ganhos observados derivam da estrutura dos dados, e não da modelagem em si.

O artigo está organizado da seguinte forma: a Seção 2 apresenta a revisão de literatura sobre mineração de processos, clusterização e privacidade, contextualizando o marco legal brasileiro (AALST, 2016; SONG; GÜNTHER; AALST, 2009; BRASIL, 1988; PIAUÍ, 2016; BRASIL, 2018). A Seção 3 detalha a metodologia, desde a extração do *log* até o protocolo experimental. A Seção 4 apresenta os resultados das predições e discute as limitações. A Seção 5 conclui o estudo respondendo às hipóteses testadas. O Apêndice A documenta as medidas e o Apêndice B traz tabelas adicionais. O Anexo A reproduz a autorização institucional para uso dos dados.

2 REVISÃO DE LITERATURA E MARCO NORMATIVO

Este trabalho situa-se na interseção de duas literaturas distintas: o Direito Administrativo, que estabelece os requisitos de transparência e inteligibilidade dos procedimentos públicos, e a Ciência da Computação (Mineração de Processos), que fornece as técnicas para reconstruir o fluxo desses procedimentos a partir de registros transacionais.

2.1 Transparência, auditabilidade e procedimento administrativo

A literatura sobre transparência administrativa demonstra que a simples disponibilização de dados não garante *accountability* (ANANNY; CRAWFORD, 2018; JANSSEN; CHARALABIDIS; ZUIDERWIJK, 2012). A doutrina brasileira reforça que a transparência exige "publicidade qualificada", na qual a informação deve ser não apenas acessível, mas inteligível (BAPTISTA; NETTO, 2023, p. 245). Essa exigência demanda a materialização clara do percurso procedimental percorrido pelos agentes públicos (BAPTISTA; NETTO, 2023, p. 255–256).

No escopo dos sistemas automatizados, Suksi (2021) argumenta que as salvaguardas processuais tradicionais se perdem se o fluxo não for inspecionável. Embora pesquisas anteriores já apliquem extração de informações em documentos jurídicos (BRANTING et al., 2025; TINARRAGE et al., 2025; VIANNA; MOURA; SILVA, 2024), a geração de taxonomias não supervisionadas requer mecanismos claros para lidar com as limitações dos registros originais (MEDVEDEVA; WIELING; VOLS, 2023; NICKERSON; VARSHNEY; MUNTERMANN, 2013).

2.2 Marco normativo brasileiro

2.2.1 Princípios constitucionais e o dever de transparência ativa

A administração pública brasileira subordina-se aos princípios do art. 37 da Constituição de 1988 (BRASIL, 1988): legalidade, impessoalidade, moralidade, publicidade e eficiência. Para fins de avaliação de registros de atividades, a eficiência traduz-se na celeridade e economia processual, coibindo laços de retrabalho e paralisações desnecessárias (CHICÓSKI, 2004, p. 180-185). Grandezas contínuas capturadas nos *logs* (como tempo decorrido e repetições) funcionam como indicadores empíricos desses princípios.

Em âmbito estadual, a lei de processo administrativo do Piauí (Lei nº 6.782/2016) posiciona a transparência e a oficialidade como princípios basilares (PIAUÍ, 2016, art. 2º), reforçando que o tempo ocioso do sistema é responsabilidade da Administração, e não apenas do requerente.

Duas legislações operacionais detalham esse dever: a Lei de Acesso à Informação (LAI) (BRASIL, 2011), que exige a disponibilização de dados estruturados e legíveis por máquina (art. 8º, § 3º, III), e o Código de Defesa dos Usuários de Serviços Públicos (BRASIL, 2017), que obriga a publicação proativa das "principais etapas para processamento do serviço"(art. 7º, § 2º, III). Juntos, esses diplomas estabelecem o requisito legal que o catálogo proposto neste artigo visa atender tecnicamente.

2.2.2 O alcance material sobre procedimentos internos

Há debate doutrinário sobre a extensão da Lei nº 13.460/2017 a procedimentos essencialmente internos, como os da SEAD-PI, onde o servidor atua como parte (BRASIL. Ministério da Transparência e Controladoria-Geral da União, 2018; MARRARA, 2018; BRASIL. Controladoria-Geral da União, 2024; JURUENA; VALLE, 2021). Independentemente de interpretações extensivas ou restritivas da norma, a construção metodológica de um catálogo inspecionável encontra respaldo direto no princípio de publicidade proativa da LAI e no imperativo de otimização de processos estabelecido pela Lei do Governo Digital (BRASIL, 2021). Omitir a rastreabilidade do fluxo processual inviabiliza a detecção de gargalos e, consequentemente, o cumprimento do dever de otimização.

Conforme demonstrado por Brauneis e Goodman (2018), a maior barreira para a auditoria de processos não é a recusa em fornecer informações, mas o fato de que a consolidação desses dados frequentemente nunca foi realizada. O presente trabalho preenche essa lacuna ao gerar um catálogo rastreável e legível por máquina, diretamente derivado dos eventos reais.

2.2.3 Anonimização e Proteção de Dados (LGPD)

O art. 12 da Lei Geral de Proteção de Dados (LGPD) (BRASIL, 2018) delimita que dados anonimizados não são considerados dados pessoais, desde que o processo de anonimização seja irreversível por meios razoáveis. Como um traço de eventos pode atuar como uma "impressão digital comportamental"(MANNHARDT et al., 2019), a técnica de anonimização implementada

nesta pesquisa atua no texto livre dos documentos (substituindo entidades por marcadores), configurando-se como um requisito legal estrito avaliado em relação ao custo de utilidade do modelo preditivo.

2.2.4 Limitação sistêmica: a ausência de restrição de percurso

Um fator arquitetural fundamental justifica a necessidade de derivar o catálogo (abordagem *bottom-up*) em vez de adotar a classificação oficial do SEI. O sistema registra ações, mas não impõe validações rígidas de sequência com base no tipo de processo declarado. Dois processos idênticos na taxonomia podem possuir trajetórias disjuntas. Consequentemente, a variação não é uma anomalia, mas o comportamento nativo de um sistema flexível. Sem uma especificação de fluxo *hard-coded*, a única representação confiável do estado atual (*as-is*) é aquela extraída do *log* efetivo.

2.3 Mineração de processos e clusterização de traços

Devido à alta heterogeneidade, a mineração de um único modelo a partir de *logs* administrativos produz resultados imprecisos ("espaguete"). A solução consolidada na literatura consiste em particionar os registros primeiramente e, em seguida, descobrir modelos especializados para cada agrupamento (GRECO et al., 2006). Diferentes representações de perfil de traços resultam em partições distintas (SONG; GÜNTHER; AALST, 2009; BOSE; AALST, 2009; KONINCK; BROUCKE; WEERDT, 2018).

A diferença metodológica deste trabalho reside no posicionamento da métrica de utilidade: estende-se o princípio de avaliar um agrupamento pela qualidade do modelo que ele habilita a jusante (como visto no ActiTraC (WEERDT et al., 2013)), aplicando-o à predição externa de próxima atividade. Em contexto brasileiro, Araújo et al. (2025) aplicaram técnicas similares a processos judiciais. No entanto, ao contrário do judiciário, que possui códigos processuais estritos, a tramitação administrativa aqui estudada carece de uma especificação canônica correspondente, reforçando a necessidade da descoberta empírica.

2.4 Modelos sequenciais e métricas de avaliação

O treinamento de modelos sequenciais especializados por grupo já foi explorado utilizando misturas de cadeias de Markov (FERREIRA et al., 2007) e agrupamento de prefixos para predição em tempo de execução (FRANCESCOMARINO et al., 2019). A literatura aponta que a codificação da sequência afeta significativamente o desempenho (TEINEMAA et al., 2019), e frequentemente modelos mais interpretáveis sacrificam acurácia (TAX; TEINEMAA; ZELST, 2020). O diferencial do presente artigo inclui o uso de casos concluídos completos, a avaliação cruzada de cinco famílias de modelos neurais e estocásticos (incluindo RNNs (TAX et al., 2017) e baseados em atenção (BUKHSH; SAEED; DIJKMAN, 2021)), e a confrontação contra

controles embaralhados.

2.5 Índices internos e privacidade no setor público

Índices internos de clusterização (como Silhouette, Davies-Bouldin e DBCV) foram originalmente concebidos como ferramentas relativas (ROUSSEEUW, 1987; MOULAVI et al., 2014). Recentes estudos empíricos indicam que otimizar partições guiando-se exclusivamente por essas métricas muitas vezes não reflete utilidade real em tarefas a jusante (YERBURY et al., 2025; GAGOLEWSKI; BARTOSZUK; CENA, 2021; LUXBURG; WILLIAMSON; GUYON, 2012). A contribuição deste trabalho nesse debate é demonstrar o comportamento destas métricas sobre um corpus administrativo operado sob distintas famílias algorítmicas.

Por fim, no que tange à mineração no setor público (AALST et al., 2010; ARAUJO et al., 2023), a preservação de utilidade analítica frente a restrições de privacidade ganha destaque. Autores exploraram garantias de k-anonimato em atributos contextuais (FAHRENKROG-PETERSEN; AA; WEIDLICH, 2020; FERRÃO; PRATA; FAZENDEIRO, 2022) e desidentificação textual para tarefas supervisionadas (LOTHRITZ et al., 2023). Aqui, mede-se o impacto da desidentificação automatizada de texto livre sobre o agrupamento de traços e a predição da próxima atividade.

3 PROCEDIMENTOS METODOLÓGICOS

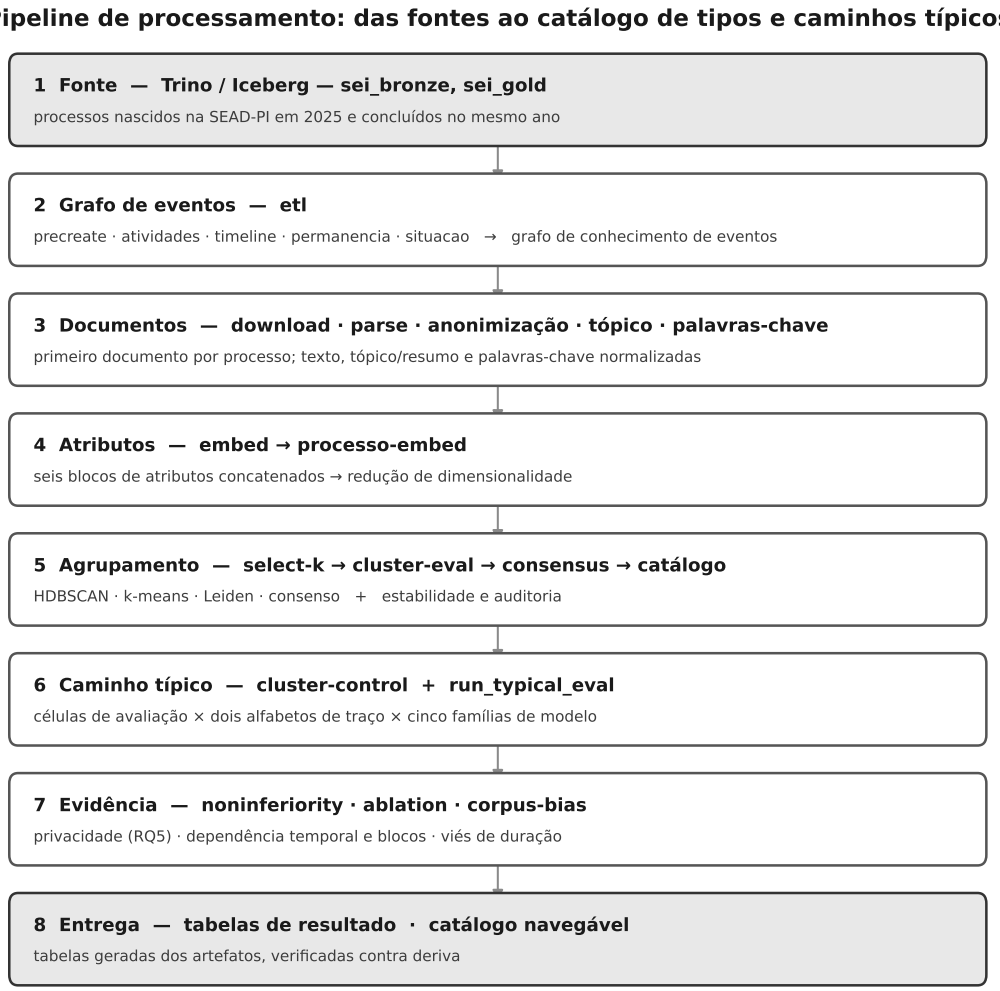
O *pipeline* de processamento desta pesquisa (Figura 1) foi desenhado para garantir reprodutibilidade estrita. Cada etapa registra um identificador de versão do código, os parâmetros utilizados e o resumo criptográfico (*hash*) dos dados de entrada. Dessa forma, todos os resultados podem ser regerados deterministicamente a partir dos artefatos salvos. O código-fonte integral desenvolvido para este estudo está disponível publicamente no repositório GitHub: <https://github.com/gabrielfmcoelho/Modelagem-de-tipos-de-processo-e-de-caminhos-tipicos-a-partir-de-registros-de-atividades>.

3.1 Caracterização da Pesquisa e Posicionalidade

Trata-se de uma pesquisa aplicada e quantitativa, caracterizada como estudo de caso único na SEAD-PI, com dados do ano de 2025. Conforme declarado na introdução, o vínculo funcional do autor com a secretaria exigiu a adoção de salvaguardas rigorosas (anonimização automatizada, processamento local e validação contra *baselines* cegas) para evitar vieses e garantir o alinhamento com a autorização institucional de tratamento de dados (PIAUÍ. Secretaria de Administração do Estado do Piauí, 2026).

Neste texto, adota-se a seguinte convenção: **processo administrativo** refere-se ao caso individual analisado; **tipo de processo** é o agrupamento resultante (o *cluster*); **traço** é a sequência de eventos de um processo; e **ação** é a tipologia do andamento registrado pelo sistema.

Figura 1: Etapas do *pipeline* de processamento, da extração no *data lake* ao catálogo de tipos de processo e caminhos típicos.



O fluxo ilustra a sequência de extração, anonimização, vetorização, agrupamento e geração de caminhos típicos.

3.2 Cenário, Corpus e Recorte Analítico

O SEI não restringe as trajetórias dos processos administrativos. Embora as ações sigam ordem cronológica, um processo pode tramitar simultaneamente em múltiplas unidades. Para viabilizar a modelagem sequencial, este comportamento concorrente foi linearizado adotando-se a ordem cronológica estrita dos carimbos de tempo dos eventos.

Os dados foram extraídos do *data lakehouse* da SEAD-PI (tabelas Iceberg via Trino). O recorte incluiu exclusivamente processos iniciados e concluídos na Secretaria no ano civil de 2025 que possuíam documento inicial legível. De 12.621 processos gerados, 5.445 foram carregados e **5.243** atenderam a todos os critérios e compõem o corpus da análise.

3.2.1 Viés de Censura à Direita

Exigir a conclusão dentro do mesmo ano civil trunca a amostra, penalizando processos longos iniciados nos últimos meses do ano. Estimou-se um déficit de 18,2% na população concluída, concentrado em trâmites prolongados. Consequentemente, o corpus não reflete durações médias globais de processamento, limitando inferências sobre eficiência temporal absoluta (Tabela 1).

Tabela 1: Censura à direita por mês de abertura.

mês	observados	dias disponíveis	vida mediana	vida máxima	excl. estimada
2025-01	474	365	21	343	0,0%
2025-02	619	334	14	290	0,2%
2025-03	478	306	17	284	0,8%
2025-04	470	275	25	244	2,1%
2025-05	415	245	24	225	5,1%
2025-06	621	214	18	204	21,7%
2025-07	653	184	12	166	24,1%
2025-08	398	153	18	129	26,2%
2025-09	539	122	10	105	29,3%
2025-10	381	92	10	75	31,9%
2025-11	268	61	5	42	35,9%
2025-12	129	31	5	29	44,5%

Observados 5.445; verdadeiro estimado 6.658; ausentes estimados **1.213** (18,2%). Limite inferior: o próprio mês de referência está truncado.

3.3 Modelagem: Grafo de Conhecimento de Eventos

Os *logs* transacionais foram estruturados em um Grafo de Conhecimento de Eventos (AALST, 2016; ESSER; FAHLAND, 2021). A construção ocorreu em três etapas: 1. **Ingestão de Dimensões:** Criação de nós para unidades, usuários e tipos de procedimento. 2. **Anexação de Atividades:** Vinculação de cada atividade ao processo, unidade, usuário, ação e documento. 3. **Encadeamento Sequencial:** Conexão temporal das atividades do mesmo processo via relações de precedência direta.

A partir do grafo, derivaram-se as métricas de tempo de posse e retrabalho. Os traços gerados foram congelados em disco para isolar as fases de agrupamento e avaliação do banco

de dados transacional.

3.4 Processamento do Documento Inicial e Anonimização

Por exigência contratual da autorização de pesquisa (PIAUÍ. Secretaria de Administração do Estado do Piauí, 2026), a anonimização de dados pessoais antecedeu qualquer vetorização. O documento inicial foi convertido para texto plano (via extração nativa ou visão computacional local). Em seguida, aplicou-se uma dupla camada de detecção e supressão: * **Mecanismos baseados em regras:** Validação de CPFs, CNPJs, e-mails e matrículas funcionais. * **Reconhecimento de Entidades Nomeadas (NER):** Aplicação de um modelo neural de esquema aberto (ZARATIANA et al., 2025) para substituir nomes próprios e informações sensíveis por marcadores consistentes (*tokens* consistentes baseados no *hash* da entidade, preservando a correferência).

A partir do texto limpo, um modelo de linguagem de pesos abertos gerou, para cada processo, um **tópico** e um **resumo** de uma frase, atuando como um filtro de ruído semântico. Além disso, extraiu-se um vocabulário controlado de palavras-chave através da unificação de n-gramas com similaridade de Dice $\geq 0,9$.

Para conformidade jurídica, toda inferência de rede neural foi executada no *cluster* de alto desempenho local (Mandu, GPUs NVIDIA) do Governo do Estado do Piauí, sem chamadas a APIs externas.

3.5 Vetorização e Agrupamento

Cada processo administrativo foi representado pela concatenação de seis blocos de atributos, posteriormente reduzidos a 50 dimensões via UMAP (MCINNES; HEALY; MELVILLE, 2018) (distância de cosseno): 1. *Embeddings* do documento inicial (1.024 dimensões, via BGE-M3 (CHEN et al., 2024)). 2. *Embeddings* do tópico e resumo gerados (1.024 dimensões). 3. TF-IDF das unidades organizacionais visitadas (500 dimensões). 4. TF-IDF das transições entre unidades (1.000 dimensões). 5. Histograma de tipos de ações (48 dimensões). 6. TF-IDF das palavras-chave do documento (517 dimensões).

O agrupamento operou sobre esse espaço vetorial utilizando três famílias algorítmicas, varrendo hiperparâmetros para garantir robustez aos métodos: **HDBSCAN** (densidade) (MCINNES; HEALY, 2017), **K-means** (centroides) e **Leiden** (modularidade em grafos) (TRAAG; WALTMAN; ECK, 2019). Essa grade gerou 14 configurações de clusterização (sete por braço: anonimizado vs. bruto). Processos não atribuídos pelo modelo de densidade (ruído) foram realocados ao centroide mais próximo para equalizar a população de avaliação entre os algoritmos.

3.6 Alfabetos de Traço e Caminhos Típicos

A avaliação ocorreu separadamente sob três abstrações de alfabeto (Figura 2):

Figura 2: Um mesmo processo administrativo renderizado nos três alfabetos de traço.

Alfabeto de ação por unidade — excerto dos dezoito estados:
`GERACAO-PROCEDIMENTO@UNIDADE-A` · `GERACAO-DOCUMENTO@UNIDADE-A` ·
`ASSINATURA-DOCUMENTO@UNIDADE-A` · `CONCLUSAO-AUTOMATICA@UNIDADE-A` ·
`PROCESSO-REMETIDO@UNIDADE-B` · `PROCESSO-RECEBIDO@UNIDADE-B` ·
`GERACAO-DOCUMENTO@UNIDADE-B` · . . . · `CONCLUSAO-PROCESSO@UNIDADE-A`

Alfabeto de roteamento — os mesmos dezoito estados, colapsados em três:
`UNIDADE-A` → `UNIDADE-B` → `UNIDADE-A`

Alfabeto de procedimento — os mesmos dezoito estados, abstraídos do organograma:
`GERACAO-PROCEDIMENTO` → `GERACAO-DOCUMENTO` → `ASSINATURA-DOCUMENTO` →
`PROCESSO-REMETIDO` → `PROCESSO-RECEBIDO` → `GERACAO-DOCUMENTO` → . . . →
`CONCLUSAO-PROCESSO`

Nota: O alfabeto de ação por unidade conserva o que se fez e onde; o de roteamento conserva apenas por onde o processo passou; o de procedimento conserva apenas o que se fez. Os dois últimos colapsam repetições consecutivas, avaliando populações distintas. A diferença central é a granularidade da representação: `ação@unidade` preserva localização, `roteamento` preserva trajetória e `procedimento` preserva ação.

* **Ação por Unidade:** Estado completo não projetado (*ação@unidade*). * **Roteamento:** Sequência apenas das unidades organizacionais (foco organizacional). * **Procedimento:** Sequência apenas das ações executadas (foco procedimental).

Para cada *cluster* contendo ao menos 30 processos, ajustaram-se seis geradores sequenciais para predizer o próximo evento e compor o "caminho típico": Markov (3ª ordem), Grafo de Precedência Direta (DFG), GRU (CHO et al., 2014), LSTM (HOCHREITER; SCHMIDHUBER, 1997), Transformer (VASWANI et al., 2017) e Redes Convolucionais em Grafos (GNN) (KIPF; WELLING, 2017). Os hiperparâmetros das redes neurais foram fixados para evitar que a comparação capturasse apenas esforço de sintonia.

A geração foi submetida a uma decodificação restrita via máquina de estados, impedindo predições que violassem as regras sistêmicas de movimentação do SEI (ex: concluir um processo nunca recebido).

3.7 Protocolo de Avaliação e Variáveis de Controle

Os processos foram particionados em 70% (treino) e 30% (teste). A métrica primária foi a **acurácia de próximo passo**, complementada por validações de sustentação de caminho (cobertura e suporte de transições observadas na realidade).

Para isolar a qualidade da modelagem estrutural do mero "dividendo de partição"(facilidade inerente de prever vocabulários menores em grupos menores), utilizaram-se três linhas de base: 1. **Sucessor Intragrupo:** Predição pela frequência máxima de transição. 2. **Modelo Global:** Um único modelo (Markov 3ª ordem) treinado sobre todo o corpus. 3. **Partição Embaralhada:** Troca aleatória de rótulos dos processos, preservando tamanho e quantidade dos clusters, mas destruindo a pertinência semântica.

O estimando principal (Δ^*) consistiu na diferença de acurácia agregada ponderada entre

a partição real proposta e a sua equivalente embaralhada. Uma partição cujo Δ^* não seja significativamente positivo foi considerada como não portadora de sinal latente útil.

4 RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados empíricos da aplicação do *pipeline* sobre o corpus de 5.243 processos concluídos na SEAD-PI em 2025. A análise divide-se na avaliação do catálogo emergente frente à taxonomia oficial, no impacto dos atributos, na validação das partições via índices internos e no desempenho preditivo dos caminhos típicos.

A avaliação foi estruturada em 14 agrupamentos, distribuídos por três alfabetos de traço (ação por unidade, roteamento e procedimento) e testados contra seis famílias de modelo, totalizando 84 células de avaliação, 4.323 grupos e 25.938 modelos treinados.

4.1 O Catálogo Emergente vs. Taxonomia Declarada

O agrupamento dos 5.243 processos produziu entre 40 e 108 tipos ao longo das 14 configurações (com tamanho mediano variando de 39 a 94 processos). Nenhum processo ficou sem atribuição, visto que o ruído dos algoritmos de densidade foi realocado ao grupo mais próximo. A etapa de auditoria confirmou a regerabilidade exata (1,0) de todas as 14 partições a partir dos seus atributos.

Ao confrontar as partições emergentes com a taxonomia declarada pela administração, a concordância demonstrou-se moderada (Tabela 2). O Adjusted Rand Index (ARI) variou de 0,116 a 0,145 nos seis agrupamentos principais.

Tabela 2: Concordância entre a partição emergente e a taxonomia declarada.

agrupamento	escopo	n	maioria	pureza	NMI	ARI
exp-anon/hdbscan	todos	5.243	0,302	0,730	0,530	0,145
exp-anon/hdbscan	excl. genérica	3.660	0,208	0,775	0,621	0,283
exp-anon/kmeans	todos	5.243	0,302	0,735	0,531	0,132
exp-anon/kmeans	excl. genérica	3.660	0,208	0,784	0,624	0,259
exp-anon/leiden	todos	5.243	0,302	0,727	0,521	0,116
exp-anon/leiden	excl. genérica	3.660	0,208	0,776	0,613	0,230
exp-raw/hdbscan	todos	5.243	0,302	0,728	0,527	0,138
exp-raw/hdbscan	excl. genérica	3.660	0,208	0,775	0,621	0,277
exp-raw/kmeans	todos	5.243	0,302	0,738	0,531	0,132
exp-raw/kmeans	excl. genérica	3.660	0,208	0,784	0,622	0,255
exp-raw/leiden	todos	5.243	0,302	0,723	0,524	0,120
exp-raw/leiden	excl. genérica	3.660	0,208	0,780	0,618	0,235

Essa discordância é impulsionada majoritariamente por uma única classe genérica ("docu-

mentos oficiais"), que abrange 30,2% do corpus. Ao removê-la, o ARI salta para a faixa de 0,230 a 0,283. Para validar se o impacto advém do tamanho da classe ou de sua natureza, a Tabela 3 testa essa remoção contra uma hipótese nula pareada por volume. O resultado indica que remover partições aleatórias de tamanho equivalente degrada o ARI, confirmando que a taxonomia oficial perde precisão justamente por utilizar rótulos "guarda-chuva"de caráter arquivístico, em vez de capturar o fluxo procedimental real.

Tabela 3: A classe genérica contra uma hipótese nula de classes aleatórias de mesmo tamanho.

agrupamento	ARI total	ARI excl.	média nula	máx. nulo	≥ obs.	z
exp-raw/hdbscan	0,1383	0,2767	0,1010 ± 0,0189	0,1311	0/724	9,3
exp-raw/kmeans	0,1324	0,2548	0,0988 ± 0,0106	0,1231	0/724	14,8
exp-raw/leiden	0,1197	0,2348	0,0885 ± 0,0102	0,1076	0/724	14,3
exp-anon/hdbscan	0,1450	0,2831	0,1072 ± 0,0187	0,1375	0/724	9,4
exp-anon/kmeans	0,1317	0,2585	0,0974 ± 0,0110	0,1225	0/724	14,6
exp-anon/leiden	0,1161	0,2303	0,0851 ± 0,0102	0,1068	0/724	14,2

Nula: descartar um conjunto aleatório de classes declaradas inteiras somando até 10% do tamanho da classe genérica e repontuar. Remover classes aleatórias do mesmo tamanho reduz a concordância; remover a classe genérica a aumenta. Nenhum sorteio nulo alcança o valor observado em qualquer agrupamento.

4.2 Impacto dos Blocos de Atributos e Dependência Temporal

A Tabela 4 documenta o estudo de ablação realizado sobre o agrupamento por densidade (braço anonimizado). A remoção do bloco de palavras-chave reduz o ARI (0,596) a níveis comparáveis ao descarte de metade do histórico transacional de cada processo (0,649). Truncar a linha do tempo dos casos a 25% reduz o ARI para 0,467, indicando que a caracterização precisa do processo se consolida no seu histórico de tramitação, e não apenas no documento de abertura.

Tabela 4: Remoção controlada de blocos de atributos e de dependência temporal.

variante	ARI	NMI	grupos
Histórico truncado em 75%	0,798	0,895	68
Histórico truncado em 50%	0,649	0,816	70
Histórico truncado em 25%	0,467	0,717	53
Bloco de palavras-chave removido	0,596	0,838	65
Bloco de tópicos removido	0,840	0,905	71

Cada variante reconstrói os atributos sob uma única alteração e reagrupa; a concordância é medida contra a partição de histórico completo (64 grupos sobre 5.243 processos).

4.2.1 Impacto da Estrutura Temporal na Classificação

Para avaliar o quanto a estrutura temporal do processo afeta sua classificação e afastar a hipótese de que a predição possui alto desempenho apenas porque a partição agrupa processos

com base em seu histórico tardio, os modelos foram testados contra agrupamentos construídos exclusivamente com os primeiros 25% dos traços. A Tabela 5 demonstra que no alfabeto de procedimento (o único onde a modelagem especializada supera consistentemente um modelo global), 92,5% do ganho de acurácia sobrevive mesmo quando o agrupador ignora o futuro do processo. Nos demais alfabetos, o ganho aproxima-se do ruído residual, confirmando a robustez da classificação temporal e estrutural do método.

Tabela 5: Ganho a jusante quando a partição vê apenas parte do histórico de cada processo.

atributos do agrupamento	grupos	por grupo	global	ganho (como avaliado)	ganho (pareado)
histórico completo	41	0,6937	0,6856	0,0081	**0,0097**
primeiros 75%	44	0,6942	0,6893	0,0049	**0,0063**
primeiros 50%	46	0,6937	0,6940	-0,0003	**0,0040**
primeiros 25%	32	0,6777	0,6924	-0,0147	**-0,0057**

Cada linha agrupa sobre atributos truncados em uma fração da linha do tempo de cada processo e então prevê sobre os traços retidos completos. As linhas não pareadas avaliam populações diferentes, de modo que seu gradiente reflete sobretudo o deslocamento da linha de base global; o bloco pareado repontua cada truncamento sobre os processos que todos os quatro avaliam. A última coluna repontua cada truncamento sobre os 1.091 processos que todos os quatro avaliam, que é a comparação que a coluna não pareada não consegue fazer.

4.3 Diferenciação entre Partições e Índices Internos

A exigência de tamanho mínimo (30 traços por grupo) e o colapso de repetições afetam a cobertura do corpus de maneira desigual. No alfabeto de roteamento, processos que tramitaram em uma única unidade perdem as transições e são descartados. Para equalizar a comparação entre as 14 configurações de agrupamento, todas foram repontuadas exclusivamente sobre o conjunto de 967 processos que sobrevivem aos cortes de todas elas (Tabela 6). A amplitude de acurácia observada entre a melhor e a pior partição foi de apenas **0,0055**, evidenciando que não há um agrupamento nitidamente superior com base exclusiva na acurácia preditiva.

4.3.1 Limitações dos Índices Internos de Validade

As Tabelas 7 e 8 reportam os índices internos de validação (Silhouette, DBCV, Davies-Bouldin, Calinski-Harabasz) e a utilidade a jusante.

Nenhum dos oito índices geométricos testados conseguiu prever de forma confiável a utilidade final dos caminhos típicos gerados (o menor p-valor sob permutação foi 0,053 para o DBCV). Métricas clássicas de compacidade, como DBCV e Silhouette, correlacionaram-se com a predição a jusante em sentidos opostos. A Tabela 9 demonstra que a forte correlação dos índices restringe-se apenas a características dimensionais, como o número de grupos (granularidade), e não à fidelidade comportamental. Por consequência, a seleção do modelo a ser publicado não deve ser delegada cegamente a métricas internas.

Tabela 6: Comparação entre agrupamentos sobre um conjunto comum de processos.

agrupamento	*n* próprio	conjunto próprio	conjunto comum	Δ
exp-raw/leiden	1.153	0,7107	**0,7129**	0,0022
exp-raw-ksil/kmeans	1.195	0,7081	**0,7127**	0,0046
exp-anon/leiden	1.122	0,7096	**0,7114**	0,0018
exp-raw-kelbow/kmeans	1.169	0,7126	**0,7111**	-0,0015
exp-raw-hcoarse/hdbscan	1.207	0,7070	**0,7109**	0,0039
exp-anon/hdbscan	1.183	0,7054	**0,7107**	0,0053
exp-anon-hcoarse/hdbscan	1.199	0,7072	**0,7101**	0,0029
exp-raw/hdbscan	1.185	0,7030	**0,7098**	0,0068
exp-anon/kmeans	1.186	0,7058	**0,7094**	0,0036
exp-raw-lres/leiden	1.117	0,7046	**0,7093**	0,0047
exp-anon-lres/leiden	1.025	0,7049	**0,7091**	0,0042
exp-raw/kmeans	1.183	0,7067	**0,7088**	0,0021
exp-anon-kelbow/kmeans	1.170	0,7042	**0,7074**	0,0032
exp-anon-ksil/kmeans	1.195	0,7038	**0,7074**	0,0036

Todos os agrupamentos repontuados sobre os 967 processos que todos eles avaliam. Amplitude no conjunto comum: **0,0055**.

Tabela 7: Índices internos de validade e qualidade a jusante, por agrupamento.

agrupamento	a jusante	DBCV	Silhouette	Davies–Bouldin	ruído	grupos	tamanho mediano
exp-raw-kelbow/kmeans	0,445	-0,018	0,731	0,569	0,000	70	62
exp-raw/leiden	0,442	0,129	0,589	0,845	0,000	71	54
exp-raw-lres/leiden	0,426	0,094	0,647	0,807	0,000	98	51
exp-raw/hdbscan	0,411	0,018	0,688	0,861	0,000	66	60
exp-anon/leiden	0,405	0,064	0,546	0,932	0,000	75	54
exp-anon-hcoarse/hdbscan	0,399	-0,075	0,573	0,733	0,000	40	94
exp-anon-lres/leiden	0,391	0,014	0,596	0,941	0,000	108	39
exp-raw/kmeans	0,391	-0,012	0,737	0,539	0,000	66	64
exp-raw-ksil/kmeans	0,377	-0,097	0,760	0,535	0,000	60	72
exp-anon/hdbscan	0,375	-0,101	0,617	0,764	0,000	64	56
exp-anon/kmeans	0,372	-0,066	0,732	0,586	0,000	64	75
exp-raw-hcoarse/hdbscan	0,371	-0,075	0,662	0,748	0,000	42	80
exp-anon-ksil/kmeans	0,342	-0,043	0,757	0,540	0,000	60	71
exp-anon-kelbow/kmeans	0,333	-0,007	0,744	0,561	0,000	70	64

Uma linha por agrupamento, todas no mesmo espaço reduzido. As correlações da Tabela 8 são calculadas sobre estas colunas. A taxa de ruído é a parcela de processos que o algoritmo deixa sem atribuição; os métodos por densidade são os únicos em que ela é diferente de zero.

Tabela 8: Índices internos de validade contra a utilidade a jusante.

índice	ρ	p
DBCV	0,538	0,053
Silhouette	-0,516	0,060
Davies–Bouldin	0,464	0,100
Calinski–Harabasz	-0,270	0,354
Taxa de ruído (recusada)	-0,055	0,853
Número de grupos	0,501	0,073
Tamanho mediano de grupo	-0,524	0,061

Correlação de postos de Spearman com a qualidade a jusante em 14 agrupamentos; teste de permutação com 20.000 sorteios. A medida a jusante abrange 0,112 (34% relativo).

Tabela 9: O que os índices de validade de fato acompanham.

relação	população	ρ
Silhouette vs. parcela de processos descartados como ruído	todos os 14	-0,308
Parcela descartada vs. acurácia no conjunto próprio da partição	todos os 14	-0,204
Silhouette vs. tamanho mediano de grupo	cob. total 14	0,427
Silhouette vs. número de grupos	cob. total 14	-0,325
Número de grupos vs. cobertura	cob. total 14	-0,991
Silhouette vs. cobertura	cob. total 14	0,341
Silhouette vs. acurácia no conjunto comum	cob. total 14	**-0,392**
DBCV vs. acurácia no conjunto comum	cob. total 14	**-0,057**
Silhouette vs. acurácia, apenas grupos pequenos (top-1 médio 0,623)	233 grupos, 14 valores	-0,151
Silhouette vs. acurácia, apenas grupos médios (top-1 médio 0,655)	267 grupos, 14 valores	-0,009
Silhouette vs. acurácia, apenas grupos grandes (top-1 médio 0,781)	89 grupos, 14 valores	0,074

A granularidade é a relação que resiste ao escrutínio neste tamanho de amostra. As linhas de cobertura são em grande medida uma reformulação dela (a correlação parcial dado o tamanho mediano de grupo é pequena), e a diferença entre as correlações de cobertura e de acurácia não é resolvível aqui – seu intervalo bootstrap sobre as configurações inclui zero. As linhas de faixa carregam apenas tantos valores distintos de silhouette quantas são as partições, e não quantos são os grupos, de modo que constituem evidência muito mais fraca do que suas contagens de grupos sugerem.

4.4 Avaliação Preditiva contra Linhas de Base

A capacidade preditiva das seis famílias de modelos foi submetida a 252 comparações contra controles estritos (Tabelas 10, 13).

4.4.1 Comparação contra Partições Embaralhadas (Δ^*)

Para isolar o valor informacional do agrupamento em relação ao mero "dividendo de partição"(facilidade de prever classes em vocabulários menores), utilizou-se a métrica Δ^*: a diferença de acurácia entre a partição real e uma versão com os mesmos tamanhos e populações, porém com a pertinência dos rótulos embaralhada.

O Δ^* mostrou-se positivo em **100% das 252 comparações**. No alfabeto de ação por unidade, atingiu de 0,165 a 0,328; em roteamento, de 0,143 a 0,285; e em procedimento, de 0,119 a 0,177. A pertença aos grupos carrega, portanto, um sinal estrutural latente válido que a taxonomia oficial não reflete.

Tabela 10: Acurácia do próximo passo contra três linhas de base, alfabeto de ação por unidade.

melhor sel.	sucessor	global	embaralhado	Δ família fixa	Δ melhor família	F1 de arestas	F1 de arestas embaralhado	Δ^* F1 de arestas
0,722	0,632	0,712	0,512	**0,000**	0,003	0,501	0,361	0,140

"melhor selecionado" toma o máximo por grupo sobre todas as famílias de modelo, de modo que o seu ganho sobre uma linha de base global de família única não é termo a termo; as colunas Δ mantêm a família fixa. Δ ainda contém o que uma partição desta distribuição de tamanhos obtém por si só, razão pela qual a coluna embaralhada é reportada ao lado e a contribuição própria da partição é separada na sua própria tabela. edge-F1 é a média harmônica entre a cobertura de arestas de precedência direta e o seu uso; é uma estatística de grupo e não uma saída de modelo, logo assume um único valor por partição e não pode variar por família de modelo. Todo número é medido dentro de um alfabeto, contra uma linha de base que enfrenta o mesmo vocabulário; os alfabetos nunca são tabulados em conjunto, porque acurácias sobre vocabulários de tamanhos diferentes não são a mesma grandeza.

Tabela 11: Acurácia do próximo passo contra três linhas de base, alfabeto de roteamento.

melhor sel.	sucessor	global	embaralhado	Δ família fixa	Δ melhor família	F1 de arestas	F1 de arestas embaralhado	Δ^* F1 de arestas
0,721	0,481	0,689	0,517	**0,010**	0,023	0,545	0,425	0,120

"melhor selecionado" toma o máximo por grupo sobre todas as famílias de modelo, de modo que o seu ganho sobre uma linha de base global de família única não é termo a termo; as colunas Δ mantêm a família fixa. Δ ainda contém o que uma partição desta distribuição de tamanhos obtém por si só, razão pela qual a coluna embaralhada é reportada ao lado e a contribuição própria da partição é separada na sua própria tabela. edge-F1 é a média harmônica entre a cobertura de arestas de precedência direta e o seu uso; é uma estatística de grupo e não uma saída de modelo, logo assume um único valor por partição e não pode variar por família de modelo. Todo número é medido dentro de um alfabeto, contra uma linha de base que enfrenta o mesmo vocabulário; os alfabetos nunca são tabulados em conjunto, porque acurácias sobre vocabulários de tamanhos diferentes não são a mesma grandeza.

Tabela 12: Acurácia do próximo passo contra três linhas de base, alfabeto de ação.

melhor sel.	sucessor	global	embaralhado	Δ família fixa	Δ melhor família	F1 de arestas	F1 de arestas embaralhado	Δ^* F1 de arestas
0,760	0,649	0,624	0,607	**0,109**	0,131	0,729	0,734	-0,006

"melhor selecionado" toma o máximo por grupo sobre todas as famílias de modelo, de modo que o seu ganho sobre uma linha de base global de família única não é termo a termo; as colunas Δ mantêm a família fixa. Δ ainda contém o que uma partição desta distribuição de tamanhos obtém por si só, razão pela qual a coluna embaralhada é reportada ao lado e a contribuição própria da partição é separada na sua própria tabela. edge-F1 é a média harmônica entre a cobertura de arestas de precedência direta e o seu uso; é uma estatística de grupo e não uma saída de modelo, logo assume um único valor por partição e não pode variar por família de modelo. Todo número é medido dentro de um alfabeto, contra uma linha de base que enfrenta o mesmo vocabulário; os alfabetos nunca são tabulados em conjunto, porque acurácias sobre vocabulários de tamanhos diferentes não são a mesma grandeza.

Tabela 13: Contribuição da própria partição, alfabeto de ação por unidade.

família	top-1 real	top-1 embaralhado	Δ^* top-1	Δ^* ajustado	Δ^* cobertura
markov	0,712	0,508	**0,204**	0,186	0,088
gru	0,715	0,496	**0,219**	0,202	0,118
lstm	0,705	0,471	**0,234**	0,216	0,121
transformer	0,713	0,488	**0,225**	0,207	0,154
gnn	0,625	0,428	**0,197**	0,179	0,073
dfg	0,589	0,296	**0,293**	0,275	0,095

Δ^* é o estimando: a partição real menos o seu controle embaralhado de forma equivalente, que tem o mesmo número de grupos, a mesma distribuição de tamanhos e a mesma população, com a pertença permutada. Ajustar um modelo por família muda o que esse modelo vê, de modo que uma partição desta forma desloca a acurácia por si só; apenas o excesso sobre o controle é atribuível ao agrupamento. Δ^* ajustado subtrai adicionalmente o modelo global agregado sob ambas as partições, cancelando um pequeno artefato de ponderação. Δ^* cobertura aplica o mesmo contraste a revocação de unidades × top-1 /(1+transições não vistas). Δ^* é um critério de admissão, não uma ordenação: cresce com o número de famílias, porque especializar compensa mais quando as famílias são pequenas, de modo que partições de granularidade diferente não devem ser ordenadas por ele. Os alfabetos nunca são tabulados em conjunto.

Tabela 14: Contribuição da própria partição, alfabeto de roteamento.

família	top-1 real	top-1 embaralhado	Δ^* top-1	Δ^* ajustado	Δ^* cobertura
markov	0,698	0,507	**0,191**	0,176	0,337
gru	0,705	0,485	**0,220**	0,205	0,339
lstm	0,690	0,448	**0,242**	0,227	0,290
transformer	0,711	0,499	**0,212**	0,198	0,306
gnn	0,477	0,304	**0,173**	0,158	0,174
dfg	0,460	0,261	**0,200**	0,185	0,191

Δ^* é o estimando: a partição real menos o seu controle embaralhado de forma equivalente, que tem o mesmo número de grupos, a mesma distribuição de tamanhos e a mesma população, com a pertença permutada. Ajustar um modelo por família muda o que esse modelo vê, de modo que uma partição desta forma desloca a acurácia por si só; apenas o excesso sobre o controle é atribuível ao agrupamento. Δ^* ajustado subtrai adicionalmente o modelo global agregado sob ambas as partições, cancelando um pequeno artefato de ponderação. Δ^* cobertura aplica o mesmo contraste a revocação de unidades $\times$ top-1 /(1+transições não vistas). Δ^* é um critério de admissão, não uma ordenação: cresce com o número de famílias, porque especializar compensa mais quando as famílias são pequenas, de modo que partições de granularidade diferente não devem ser ordenadas por ele. Os alfabetos nunca são tabulados em conjunto.

Tabela 15: Contribuição da própria partição, alfabeto de ação.

família	top-1 real	top-1 embaralhado	Δ^* top-1	Δ^* ajustado
markov	0,733	0,587	**0,146**	0,152
gru	0,755	0,601	**0,153**	0,160
lstm	0,754	0,599	**0,155**	0,161
transformer	0,751	0,593	**0,158**	0,165
gnn	0,644	0,515	**0,129**	0,136
dfg	0,644	0,517	**0,126**	0,133

Δ^* é o estimando: a partição real menos o seu controle embaralhado de forma equivalente, que tem o mesmo número de grupos, a mesma distribuição de tamanhos e a mesma população, com a pertença permutada. Ajustar um modelo por família muda o que esse modelo vê, de modo que uma partição desta forma desloca a acurácia por si só; apenas o excesso sobre o controle é atribuível ao agrupamento. Δ^* ajustado subtrai adicionalmente o modelo global agregado sob ambas as partições, cancelando um pequeno artefato de ponderação. Δ^* cobertura aplica o mesmo contraste a revocação de unidades $\times$ top-1 /(1+transições não vistas). Δ^* é um critério de admissão, não uma ordenação: cresce com o número de famílias, porque especializar compensa mais quando as famílias são pequenas, de modo que partições de granularidade diferente não devem ser ordenadas por ele. Os alfabetos nunca são tabulados em conjunto.

Contudo, observou-se que o Δ^* cresce monotonicamente junto com a granularidade dos agrupamentos: grupos menores geram controles embaralhados mais fracos. Portanto, o Δ^* atua como um teste de admissibilidade estatística (comprova que há padrão), e não como uma função de ordenação para eleger a melhor partição candidata.

4.4.2 Desempenho das Famílias de Modelos e Fidelidade de Arestas

A diferença de desempenho preditivo entre modelos estocásticos clássicos e arquiteturas neurais complexas foi marginal nos três alfabetos. No alfabeto de roteamento, a cadeia de Markov de 3ª ordem alcançou 0,698 de acurácia, ficando a apenas 1,3 ponto percentual do Transformer (0,711). No alfabeto de procedimento, a cadeia de Markov marcou 0,733 contra 0,754 da arquitetura GRU (diferença de 2,2 pontos). Esses resultados indicam que modelos de menor custo computacional (baseados em matrizes de transição) entregam resultados competitivos frente a redes neurais neste domínio específico.

A métrica de fidelidade de arestas (Edge-F1), que avalia a topologia do grafo gerado, revelou que o ganho preditivo de próximo passo não se traduz necessariamente em ganho estrutural. No alfabeto de procedimento, o Edge-F1 da partição real foi 0,729 contra 0,734 do controle embaralhado ($\Delta^* = -0{,}006$). Isso demonstra que o valor do particionamento, neste caso, incide sobre a previsão da sequência linear de ações (o modelo de linguagem do traço), e não sobre a descoberta de fluxos de trabalho estruturalmente distintos.

4.4.3 Estratificação por Tamanho de Grupo e Comparação com Processos Reais

O desempenho dos modelos foi estratificado pelo número de instâncias contidas em cada *cluster*. Conforme detalhado nas tabelas de tendência por tamanho, grupos maiores tendem a gerar caminhos preditivos com menor taxa de fabricação de transições inéditas, especialmente nos alfabetos de roteamento e ação por unidade.

Tabela 16: Qualidade do caminho por tamanho de grupo, alfabeto de ação por unidade.

processos no grupo	grupos	top-1	ganho vs global	revocação de unidades	inéditas
30-50	183	0,669	0,0047	0,705	8,154
50-75	232	0,693	0,0062	0,643	2,581
75-100	130	0,669	-0,0015	0,650	3,401
100-150	109	0,725	0,0170	0,711	3,273
150-250	85	0,762	0,0108	0,774	1,331
250-	25	0,817	0,0283	0,795	0,252

O ganho é medido faixa a faixa contra um modelo global da mesma família. Grupos com menos de trinta traços não são avaliados.

Para avaliar o grau de realismo das predições, os caminhos gerados foram confrontados com o medoide (o traço real mais central de cada grupo). Constatou-se uma subgeração sistemática: os caminhos sintéticos cobrem apenas cerca de 52% a 54% das visitas de um processo real

Tabela 17: Qualidade do caminho por tamanho de grupo, alfabeto de roteamento.

processos no grupo	grupos	top-1	ganho vs global	revocação de unidades	inéditas
30-50	157	0,668	0,0361	0,737	1,226
50-75	148	0,657	0,0264	0,648	0,554
75-100	111	0,665	0,0543	0,670	0,470
100-150	84	0,719	0,0383	0,702	0,393
150-250	70	0,782	0,0172	0,811	0,268
250-	19	0,830	0,0257	0,797	0,103

O ganho é medido faixa a faixa contra um modelo global da mesma família. Grupos com menos de trinta traços não são avaliados.

Tabela 18: Qualidade do caminho por tamanho de grupo, alfabeto de ação.

processos no grupo	grupos	top-1	ganho vs global	inéditas
30-50	183	0,721	0,1092	4,215
50-75	232	0,743	0,1340	1,794
75-100	130	0,718	0,1229	1,990
100-150	109	0,757	0,1313	2,675
150-250	85	0,793	0,1450	2,817
250-	25	0,827	0,1797	5,155

O ganho é medido faixa a faixa contra um modelo global da mesma família. Grupos com menos de trinta traços não são avaliados.

e são estruturalmente mais curtos. No alfabeto de roteamento, os modelos generativos (como Markov e GRU) produziram rotas mais "limpas"(menos idiossincráticas e com menor fabricação de arestas) que o próprio medoide. No alfabeto de procedimento, entretanto, o medoide superou todos os geradores sintéticos ao apresentar uma fabricação quase nula de arestas inéditas (0,415 transições não observadas, contra 2,993 da GRU).

4.5 Conformidade com as Regras de Tramitação

A viabilidade técnica de um catálogo auditável exige que os caminhos gerados não violem as lógicas fundamentais do sistema de origem. A Tabela 19 consolida os testes de conformidade em relação às regras de pareamento (envio e recebimento) do SEI.

Tabela 19: Conformidade às regras na geração irrestrita, comparada aos próprios registros de atividades.

fonte	passos válidos	traços totalmente válidos
markov	0,9978	0,9486
dfg	0,9934	0,9337
gnn	0,9869	0,8756
gru	0,9930	0,8894
lstm	0,9908	0,8639
transformer	0,9900	0,8719
registros de atividades reais	0,9986	0,9162

A decodificação restrita é válida por construção e não é tabulada.

No alfabeto de ação por unidade, a geração irrestrita obteve alta aderência: entre 86,4% e 94,9% dos traços gerados respeitaram nativamente as regras de fluxo. No entanto, no alfabeto de procedimento, as próprias instâncias reais violam a regra em larga escala (apenas 24,40% de conformidade no log original). A aplicação da decodificação restrita via máquina de estados mitigou esse problema, garantindo a validade estrutural por construção ao custo de alterar o candidato preditivo ótimo em cerca de 1,07% das decisões de roteamento.

4.6 Anonimização e Custo de Utilidade

O impacto da supressão de dados pessoais (exigida pela LGPD e pelo termo de autorização) sobre a acurácia preditiva foi avaliado comparando-se o braço bruto e o braço anonimizado processo a processo, via *bootstrap* pareado com 2.000 replicações.

Os resultados mostram que todas as 54 comparações de modelo por agrupamento foram não inferiores na margem pré-registrada $\delta = 0{,}01$. Sob a margem de sensibilidade mais restrita de $\delta = 0{,}005$, obteve-se sucesso em 49 das 54 medições. Conclui-se que a anonimização textual aplicada previamente não impõe custo estatisticamente relevante à utilidade preditiva a jusante.

4.7 Seleção da Configuração do Catálogo Final

Como a amplitude de acurácia entre as 14 partições sobre o conjunto comum foi estatisticamente mínima (0,0055) e os índices geométricos internos demonstraram-se falhos para ordenação, a seleção da partição final exigiu critérios heurísticos alinhados ao objetivo do artefato de transparência.

A Tabela 20 ilustra a pontuação dos candidatos baseada na composição de cobertura, tamanho mediano, acurácia e *silhouette*.

Tabela 20: Escolha de um entregável entre os agrupamentos, pontuada apenas no alfabeto de roteamento.

agrupamento	t-1 comum	cobertura	silh.	tam. mediano	grupos	em grupos ≥150	escore
exp-raw-ksil/kmeans	0,7127	0,751	0,760	72	60	0,324	**0,900**
exp-raw-hcoarse/hdbscan	0,7109	0,759	0,662	80	42	0,631	**0,746**
exp-raw-kelbow/kmeans	0,7111	0,735	0,731	62	70	0,310	**0,689**
exp-raw/leiden	0,7129	0,727	0,589	54	71	0,331	**0,676**
exp-anon-hcoarse/hdbscan	0,7101	0,757	0,573	94	40	0,680	**0,658**
exp-anon/kmeans	0,7094	0,747	0,732	75	64	0,331	**0,639**
exp-anon/hdbscan	0,7107	0,745	0,617	56	64	0,363	**0,594**
exp-raw/hdbscan	0,7098	0,744	0,688	60	66	0,345	**0,588**
exp-raw/kmeans	0,7088	0,741	0,737	64	66	0,321	**0,551**
exp-anon-ksil/kmeans	0,7074	0,752	0,757	71	60	0,338	**0,513**
exp-anon/leiden	0,7114	0,711	0,546	54	75	0,267	**0,491**
exp-anon-kelbow/kmeans	0,7074	0,734	0,744	64	70	0,178	**0,432**
exp-raw-lres/leiden	0,7093	0,698	0,647	51	98	0,040	**0,363**
exp-anon-lres/leiden	0,7091	0,656	0,596	39	108	0,033	**0,159**

Todo agrupamento é candidato: nenhum filtro de cobertura é aplicado, uma vez que atribuir o ruído da densidade ao grupo mais próximo já fechou o canal de descarte a montante. Os atributos são escalonados por mín–máx entre os candidatos; a acurácia é pontuada sobre o conjunto comum. Pontuado apenas no alfabeto de roteamento — os alfabetos nunca são agregados entre si, de modo que o entregável é selecionado sobre um deles, e essa escolha é uma decisão de escopo, e não uma propriedade dos dados. O mesmo candidato vence sob todas as quatro ponderações, inclusive uma que ignora inteiramente os índices de validade. "em grupos ≥150" é a fração de processos que a partição situa em grupos grandes o bastante para a faixa de baixa fabricação da Tabela 17.

A configuração selecionada para a entrega metodológica foi o **agrupamento por centroides (K-means) do braço sem anonimização com k definido pela *silhouette***. Essa parametrização assegura a formação de 60 grupos com um tamanho mediano robusto (71,5 processos) e 75,1% de cobertura do corpus avaliável. A geração dos caminhos típicos foi parametrizada utilizando a arquitetura **GRU** sob o alfabeto de **roteamento**, priorizando a interpretabilidade organizacional exigida por relatórios de conformidade pública.

4.8 Estrutura do Catálogo Entregue

Com a configuração final estabelecida, a Tabela 21 ilustra dez das 60 entradas nomeadas que compõem o artefato entregue. A tabela evidencia a dispersão intrínseca na qualidade de predição entre diferentes tipos processuais: categorias estruturadas, como "alterações contratuais"(210 processos), atingem 0,984 de acurácia de próximo passo; em contraste, agrupamentos mais difusos, como o de "justificativa de ponto", apresentam acurácia na faixa de 0,570. Por essa

razão, as métricas de suporte e o tamanho do grupo devem obrigatoriamente acompanhar a publicação de cada entrada no catálogo real.

Tabela 21: Entradas ilustrativas do catálogo: os maiores e os menores tipos avaliados.

tipo de processo (nome gerado)	processos	aval.	top-1	rec. unidades
Gestão de Contracheques e Solicitações de Pagamentos Indenizatórios	318	312	0,850	0,978
Solicitação de Autorização para Adesão a Ata de Registro de Preços	229	217	0,733	0,823
Registro de Alterações Contratuais e Consolidação Societária de Empresas	210	210	0,984	1,000
Solicitação de Pagamento de Serviços de Mão de Obra Terceirizada	198	198	0,771	0,924
Retirada de Descontos Indevidos em Contracheques de Servidores	188	188	0,770	0,916
Gestão de Pessoal e Contratações Temporárias	192	185	0,718	0,658
Justificativa e Abono de Faltas por Doença ou Trabalho Remoto	42	39	0,547	0,810
Autorização de Recebimento de Bens Arrematados em Leilão	38	35	0,640	0,816
Solicitação de Pagamento de Fornecimento de Água Tratada	31	31	0,785	0,977
Solicitação de Abono de Faltas e Justificativa de Ponto	30	30	0,570	0,857

Entradas ilustrativas do catálogo: os maiores e os menores tipos avaliados. Os nomes são gerados (Seção 3.8) e não validados; as medidas referem-se ao caminho GRU no alfabeto de roteamento, a família que mais ganha em roteamento (Seção 3.10).

4.9 Considerações de Accountability, Governança e Limitações

A transposição de um *pipeline* de *machine learning* para a esfera da auditoria pública exige salvaguardas estritas de governança. O catálogo gerado fornece um inventário rastreável e atribuível do "que de fato ocorre"na administração, atendendo às demandas de transparência ativa (LAI).

Entretanto, sua natureza é estritamente **descritiva**. Ele não deve ser instituído como norma ou padrão punitivo para avaliar desvios individuais de servidores, dado que captura variações estatísticas, e não determinações legais. Ademais, a interpretação dos resultados reportados nesta seção deve ponderar as seguintes ameaças à validade e limitações do desenho experimental:

- **Censura à Direita e Viés de Duração:** O recorte de analisar processos iniciados e concluídos dentro de uma única janela anual impõe um subdimensionamento de processos longos (estimado em 18,2% de déficit). Métricas absolutas de eficiência de tempo não são deriváveis deste corpus.

- **Subgeração Sistêmica:** Conforme medido, os modelos sintéticos sintetizam rotas que cobrem apenas cerca de metade das transições de um processo real complexo. Utilizá-los diretamente como "cartas de serviço"ao cidadão subestimaria o trâmite enfrentado.

- **Dependência de Estágio Tardio:** A vetorização dos processos incluiu todo o histórico de tramitação. Logo, os modelos não são capazes de prever com precisão a tipologia do processo *zero-shot* (no exato momento da autuação), atuando primordialmente como ferramenta *post-mortem* de auditoria.

- **Validação Humana e Linearização:** Os rótulos do catálogo foram gerados algoritmicamente (LLMs locais) e carecem de homologação por especialistas no domínio jurídico-administrativo. Além disso, a conversão de processos concorrentes em sequências cronológicas lineares pode mascarar ramificações paralelas genuínas da arquitetura do SEI.

LaTeX

5 CONSIDERAÇÕES FINAIS

Este trabalho demonstrou a viabilidade de derivar, a partir de registros transacionais brutos do sistema SEI, um catálogo auditável e estruturado dos tipos de processo administrativo executados pela SEAD-PI. A evidência produzida sustenta que o catálogo não é um artefato arbitrário: ele emerge de uma estrutura de dados real, validada em 252 comparações contra partições-controle embaralhadas.

Síntese das Hipóteses

- **H1 (Sinal estrutural):** Sustentada. O agrupamento emergente captura variações procedimentais que a taxonomia declarada não registra. O excesso de acurácia preditiva em relação às partições embaralhadas ($\Delta^* > 0$) confirmou que a pertença aos grupos carrega um sinal estrutural consistente, independente da forma da partição.

- **H2 (Critérios de decisão):** Refutada como critério automático. Os índices internos de validade (como Silhouette e DBCV) não se correlacionaram de forma robusta com a utilidade preditiva a jusante. A seleção da partição final exigiu, portanto, uma decisão baseada em pesos ponderados sobre os objetivos operativos do catálogo, e não em uma busca algorítmica autônoma.

- **H3 (Ganho preditivo):** Sustentada parcialmente. O ganho da modelagem por tipo sobre um modelo global foi positivo e significativo apenas no alfabeto de *procedimento*. Nos demais alfabetos, o ganho não superou o resíduo de agregação, indicando que a especialização por tipo é útil para predizer a sequência de ações, mas não necessariamente para descrever a estrutura de roteamento entre unidades.

Contribuição Técnica e Instrumento de Transparência

A principal contribuição deste estudo não reside apenas na acurácia preditiva, mas na entrega de um objeto auditável e regerável. Diferente da publicação de dados brutos, o catálogo produzido é atribuível: cada afirmação sobre o fluxo processual pode ser rastreada até os processos que a sustentam. Esta característica é fundamental para atender ao dever legal de transparência ativa em formato legível por máquina, permitindo que o controle externo e as unidades de otimização administrativa operem sobre um modelo do "o que de fato ocorre", em vez de apenas sobre o "o que deveria ocorrer".

Ressalta-se que este artefato tem natureza descritiva e não normativa. Ele descreve o comportamento recorrente, mas não constitui, por si, um padrão de conformidade ou uma métrica de eficiência. O uso do catálogo para fins de ranqueamento, avaliação de desempenho individual ou sanções disciplinares seria metodologicamente incorreto, dado o viés de duração detectado no corpus (que sub-representa processos longos) e a natureza técnica da predição por agrupamento.

Considerações sobre a Adoção e Governança

A viabilidade técnica do *pipeline* não depende de infraestrutura de alto desempenho, mas de governança de dados. A modelagem por cadeias de Markov, que apresentou desempenho competitivo frente a arquiteturas neurais complexas, torna o custo computacional de manutenção do catálogo irrelevante. O desafio real para a adoção reside na governança:

1. É necessário definir a cadência de atualização do catálogo, evitando a obsolescência de fluxos.

2. Recomenda-se a adoção de um limiar de volume mínimo para publicação de tipos de processo, protegendo o sigilo e a privacidade de unidades administrativas pequenas.

3. O catálogo deve ser tratado como um documento vivo, revisado periodicamente contra os novos registros de atividades, garantindo que o "típico"acompanhe a mudança da prática administrativa.

Trabalhos Futuros

A modelagem de processos administrativos pode evoluir a partir de três direções:

1. **Análise Temporal:** Expansão da janela de coleta para além de um exercício civil, eliminando o viés de censura à direita e permitindo medições precisas de duração (SLA).

2. **Agrupamento por Objetos (OCPM):** Investigação de técnicas de mineração centradas em objetos para modelar explicitamente a concorrência e a ramificação de processos, superando a linearização cronológica.

3. **Validação por Especialistas:** Avaliação qualitativa e crítica dos nomes e descrições dos tipos de processo por servidores de carreira, garantindo que a semântica gerada pelo modelo esteja alinhada à realidade administrativa institucional.

Este trabalho oferece, portanto, a base técnica e o protocolo metodológico necessários para que a administração pública transforme seus registros eletrônicos em conhecimento gerencial auditável e transparente.

Referências

AALST, W. M. P. van der. *Process mining: data science in action*. 2nd. ed. [S.l.]: Springer, 2016.

AALST, W. M. P. van der et al. Auditing 2.0: Using process mining to support tomorrow's auditor. *Computer*, v. 43, n. 3, p. 90–93, 2010.

ANANNY, M.; CRAWFORD, K. Seeing without knowing: limitations of the transparency ideal and its application to algorithmic accountability. *New Media & Society*, v. 20, n. 3, p. 973–989, 2018.

ARAUJO, R. M. de et al. Mineração de processos como ferramenta para promoção da transparência: oportunidades e desafios. *Revista da CGU*, v. 15, n. 27, p. 203–218, 2023.

ARAÚJO, T. et al. Trace clustering for judicial process simplification: identifying patterns and enhancing anaslysis. *Artificial Intelligence and Law*, 2025. Acesso em: 4 ago. 2026.

BAPTISTA, P. F.; NETTO, L. S. A. Parâmetros para o dever de transparência da administração pública. *Revista da AGU*, v. 22, n. 4, p. 243–259, dez. 2023. "A transparência é a publicidade qualificada" (p. 245); "não se pode conceber a publicidade sem que se materialize o íter procedimental percorrido pelos agentes... até a edição do ato administrativo" (pp. 255–256). Página inicial 243 inferida do rodapé 244 da página seguinte; a primeira página não traz numeração impressa. Disponível em: <https://revistaagu.agu.gov.br/index.php/AGU/article/view/3397>.

BOSE, R. P. J. C.; AALST, W. M. P. van der. Context aware trace clustering: towards improving process mining results. In: *Proceedings of the 2009 SIAM International Conference on Data Mining (SDM)*. [S.l.]: SIAM, 2009. p. 401–412.

BRANTING, K. et al. Decision support for detecting sensitive text in government records. *Artificial Intelligence and Law*, v. 33, n. 1, p. 171–197, 2025.

BRASIL. *Constituição da República Federativa do Brasil de 1988. Texto compilado, com as alterações das Emendas Constitucionais nº 19/1998 e nº 45/2004*. Brasília, DF: Presidência da República, 1988. Disponível em: <https://www.planalto.gov.br/ccivil_03/constituicao/constituicao.htm>. Acesso em: 4 ago. 2026.

BRASIL. *Lei nº 12.527, de 18 de novembro de 2011. Lei de Acesso à Informação (LAI). Regula o acesso a informações previsto no inciso XXXIII do art. 5º, no inciso II do § 3º do art. 37 e no § 2º do art. 216 da Constituição Federal*. Brasília, DF: Presidência da República, 2011. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2011-2014/2011/lei/l12527.htm>. Acesso em: 4 ago. 2026.

BRASIL. *Lei nº 13.460, de 26 de junho de 2017. Código de Defesa do Usuário dos Serviços Públicos. Dispõe sobre participação, proteção e defesa dos direitos do usuário dos serviços públicos da administração pública*. Brasília, DF: Presidência da República, 2017. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2017/lei/l13460.htm>. Acesso em: 4 ago. 2026.

BRASIL. *Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Dispõe sobre o tratamento de dados pessoais, inclusive nos meios digitais, por pessoa natural ou por pessoa jurídica de direito público ou privado*. Brasília, DF: Presidência da República, 2018. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 4 ago. 2026.

BRASIL. *Lei nº 14.129, de 29 de março de 2021. Dispõe sobre princípios, regras e instrumentos para o Governo Digital e para o aumento da eficiência pública*. 2021. Diário Oficial da União, Brasília, DF. Altera as Leis nº 7.116/1983, 12.527/2011 (LAI), 12.682/2012 e 13.460/2017. Disponível em: <http://www.planalto.gov.br/ccivil_03/_ato2019-2022/2021/lei/L14129.htm>.

BRASIL. Controladoria-Geral da União. *Portaria Normativa CGU nº 116, de 18 de março de 2024*. 2024. Diário Oficial da União, seção 1, Brasília, DF, ed. 55, p. 134, 20 mar. 2024. Art. 48: as manifestações oriundas de agentes públicos internos "receberão o mesmo tratamento das manifestações provenientes de usuários de serviços públicos"; § 2º: "aplicam-se aos agentes públicos internos as mesmas garantias e proteções destinadas aos usuários". Equiparação expressa que pressupõe distinção: argumenta nos dois sentidos e não resolve a questão. Disponível em: <https://basedeconhecimento-h.cgu.gov.br/handle/1/18642>.

BRASIL. Ministério da Transparência e Controladoria-Geral da União. *Manual de ouvidoria pública: rumo ao sistema participativo*. 2018. Brasília: CGU, nov. 2018. Revista e ampliada, atualizada pela Lei nº 13.460 e Decreto nº 9.492/2018. P. 68: "serviço público compreende tanto uma atividade administrativa (ato voltado para organização e funcionamento das estruturas estatais)... quanto uma atividade de prestação direta ou indireta de bens ou serviços"; p. 69: "conceito amplo de serviço público"; p. 70 destaca o art. 6º, VI, "d" (situação da tramitação dos processos administrativos em que o usuário figure como interessado). Disponível em: <https://repositorio.cgu.gov.br/bitstream/1/29959/14/manual_de_ouvidoria_publica.pdf>.

BRAUNEIS, R.; GOODMAN, E. P. Algorithmic transparency for the smart city. *Yale Journal of Law & Technology*, v. 20, p. 103–176, 2018.

BUKHSH, Z. A.; SAEED, A.; DIJKMAN, R. M. *ProcessTransformer: predictive business process monitoring with transformer network*. 2021. Disponível em: <https://arxiv.org/abs/2104.00721>. Preprint arXiv:2104.00721. Acesso em: 4 ago. 2026.

CHEN, J. et al. M3-embedding: multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In: *Findings of the Association for Computational Linguistics: ACL 2024*. Bangkok, Thailand: Association for Computational Linguistics, 2024. p. 2318–2335. Disponível em: <https://aclanthology.org/2024.findings-acl.137/>. Acesso em: 4 ago. 2026.

CHICÓSKI, D. O princípio da eficiência e o procedimento administrativo. *A&C — Revista de Direito Administrativo & Constitucional*, v. 4, n. 18, p. 169–196, out./dez. 2004. P. 180 reproduz a definição de Di Pietro dos dois aspectos da eficiência e sustenta que é no aspecto organizativo

que reside a relação íntima com o procedimento administrativo, “dada a necessidade de previsibilidade da atuação administrativa”. Pp. 184–185 sintetizam os cinco atributos da eficiência no processo administrativo segundo Egon Bockmann Moreira, incluindo vedação a paralisações desnecessárias e a repetição desnecessária de atos ou fases. Disponível em: <https://revistaaec.com/index.php/revistaaec/article/view/621>.

CHO, K. et al. Learning phrase representations using RNN encoder–decoder for statistical machine translation. In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Doha, Qatar: Association for Computational Linguistics, 2014. p. 1724–1734. Disponível em: <https://aclanthology.org/D14-1179/>. Acesso em: 4 ago. 2026.

ESSER, S.; FAHLAND, D. Multi-dimensional event data in graph databases. *Journal on Data Semantics*, v. 10, n. 1–2, p. 109–141, 2021.

FAHRENKROG-PETERSEN, S. A.; AA, H. van der; WEIDLICH, M. PRIPEL: Privacy-preserving event log publishing including contextual information. In: *Business Process Management (BPM 2020)*. [S.l.]: Springer, 2020, (Lecture Notes in Computer Science). p. 111–128. ISBN 978-3-030-58666-9.

FERRÃO, M. E.; PRATA, P.; FAZENDEIRO, P. Utility-driven assessment of anonymized data via clustering. *Scientific Data*, v. 9, n. 1, p. 456, 2022.

FERREIRA, D. et al. Approaching process mining with sequence clustering: Experiments and findings. In: *Business Process Management (BPM 2007)*. [S.l.]: Springer, 2007, (Lecture Notes in Computer Science). p. 360–374. ISBN 978-3-540-75183-0.

FRANCESCOMARINO, C. D. et al. Clustering-based predictive process monitoring. *IEEE Transactions on Services Computing*, v. 12, n. 6, p. 896–909, 2019.

GAGOLEWSKI, M.; BARTOSZUK, M.; CENA, A. Are cluster validity measures (in)valid? *Information Sciences*, v. 581, p. 620–636, 2021.

GRECO, G. et al. Discovering expressive process models by clustering log traces. *IEEE Transactions on Knowledge and Data Engineering*, v. 18, n. 8, p. 1010–1027, 2006.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997.

JANSSEN, M.; CHARALABIDIS, Y.; ZUIDERWIJK, A. Benefits, adoption barriers and myths of open data and open government. *Information Systems Management*, v. 29, n. 4, p. 258–268, 2012.

JURUENA, C. G.; VALLE, V. C. L. L. O usuário do serviço público e a aplicação da Lei 13.460/2017 sob o enfoque dos Poderes Executivo e Judiciário. *Seqüência — Estudos Jurídicos e Políticos*, v. 42, n. 87, 2021. Levantamento no TJPR entre 17/06/2018 e 17/06/2020: apenas duas decisões mencionaram a Lei 13.460/2017; 14 de 15 acórdãos analisados aplicaram o CDC; buscas por “Carta de Serviços ao Usuário” nos portais estadual e municipais frequentemente não retornaram resultado. Disponível em: <https://periodicos.ufsc.br/index.php/sequencia/article/view/76786>.

KIPF, T. N.; WELLING, M. Semi-supervised classification with graph convolutional networks. In: *5th International Conference on Learning Representations (ICLR 2017)*. [S.l.]: OpenReview.net, 2017. ArXiv:1609.02907.

KONINCK, P. D.; BROUCKE, S. vanden; WEERDT, J. D. act2vec, trace2vec, log2vec, and model2vec: Representation learning for business processes. In: *Business Process Management (BPM 2018)*. [S.l.]: Springer, 2018, (Lecture Notes in Computer Science). p. 305–321. ISBN 978-3-319-98648-7.

LIMA E SILVA, F. J. E. et al. Análise de processos administrativos no setor público via mineração de processos: um estudo de caso no tribunal regional eleitoral do tocantins. *Revista DCS*, v. 23, n. 88, p. e4864, 2026. ISSN 2224-4131. Disponível em: <https://ojs.revistadcs.com/index.php/revista/article/view/4864>. Acesso em: 4 ago. 2026.

LOTHRITZ, C. et al. Evaluating the impact of text de-identification on downstream NLP tasks. In: *Proceedings of the 24th Nordic Conference on Computational Linguistics (NoDaLiDa)*. Tórshavn, Faroe Islands: University of Tartu Library, 2023. p. 10–16. Disponível em: <https://aclanthology.org/2023.nodalida-1.2/>. Acesso em: 4 ago. 2026.

LUXBURG, U. von; WILLIAMSON, R. C.; GUYON, I. Clustering: Science or art? In: *Proceedings of ICML Workshop on Unsupervised and Transfer Learning*. PMLR, 2012. (Proceedings of Machine Learning Research, v. 27), p. 65–79. Disponível em: <https://proceedings.mlr.press/v27/luxburg12a.html>. Acesso em: 4 ago. 2026.

MANNHARDT, F. et al. Privacy-preserving process mining: Differential privacy for event logs. *Business & Information Systems Engineering*, v. 61, n. 5, p. 595–614, 2019.

MARRARA, T. *O Código de Defesa do Usuário de Serviços Públicos (Lei n. 13.460/2017): seis parâmetros de aplicabilidade*. 2018. Colunistas — Direito do Estado, 15 jan. 2018. Sustenta que a expressão "atividade administrativa" no art. 2º, II inclui os serviços públicos administrativos, entre os quais os prestados por certos órgãos públicos a outros; delimita, porém, o Código à função administrativa prestativa. Disponível em: <http://www.direitodoestado.com.br/colunistas/thiago-marrara/o-codigo-de-defesa-do-usuario-de-servicos-publicos-lei-n-13460-2017-seis-parametros-de-aplicabilidade>.

MCINNES, L.; HEALY, J. Accelerated hierarchical density based clustering. In: *2017 IEEE International Conference on Data Mining Workshops (ICDMW)*. [S.l.]: IEEE, 2017. p. 33–42.

MCINNES, L.; HEALY, J.; MELVILLE, J. *UMAP: uniform manifold approximation and projection for dimension reduction*. 2018. Disponível em: <https://arxiv.org/abs/1802.03426>. Preprint arXiv:1802.03426. Acesso em: 4 ago. 2026.

MEDVEDEVA, M.; WIELING, M.; VOLS, M. Rethinking the field of automatic prediction of court decisions. *Artificial Intelligence and Law*, v. 31, n. 1, p. 195–212, 2023.

MOULAVI, D. et al. Density-based clustering validation. In: *Proceedings of the 2014 SIAM International Conference on Data Mining (SDM)*. [S.l.]: SIAM, 2014. p. 839–847.

NAI, R. et al. Legal process mining for the analysis of public procurement workflows. *Computer Law & Security Review*, v. 61, p. 106283, 2026.

NICKERSON, R. C.; VARSHNEY, U.; MUNTERMANN, J. A method for taxonomy development and its application in information systems. *European Journal of Information Systems*, v. 22, n. 3, p. 336–359, 2013.

PIAUÍ. *Lei nº 6.782, de 28 de março de 2016. Regula o processo administrativo no âmbito da Administração Pública do Estado do Piauí*. Teresina, PI: Assembleia Legislativa do Estado do Piauí, 2016. Disponível em: <https://sapl.al.pi.leg.br/norma/3878>. Acesso em: 4 ago. 2026.

PIAUÍ. Secretaria de Administração do Estado do Piauí. *Termo de Ciência e Responsabilidade para o Tratamento dos Dados Pessoais - SEAD/PI*. Teresina, PI: [s.n.], 2026. Documento institucional assinado digitalmente em 10 jul. 2026. Vigência até dezembro de 2027. Reproduzido no Anexo A deste trabalho, com tarja sobre identificadores pessoais.

ROUSSEEUW, P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, v. 20, p. 53–65, 1987.

SONG, M.; GÜNTHER, C. W.; AALST, W. M. P. van der. Trace clustering in process mining. In: *Business Process Management Workshops (BPM 2008), LNBIP 17*. [S.l.]: Springer, 2009. p. 109–120.

SUKSI, M. Administrative due process when using automated decision-making in public administration: some notes from a Finnish perspective. *Artificial Intelligence and Law*, v. 29, n. 1, p. 87–110, 2021.

TAX, N.; TEINEMAA, I.; ZELST, S. J. van. An interdisciplinary comparison of sequence modeling methods for next-element prediction. *Software and Systems Modeling*, v. 19, n. 6, p. 1345–1365, 2020.

TAX, N. et al. Predictive business process monitoring with LSTM neural networks. In: *Advanced Information Systems Engineering (CAiSE 2017), LNCS 10253*. [S.l.]: Springer, 2017. p. 477–492.

TEINEMAA, I. et al. Outcome-oriented predictive process monitoring: review and benchmark. *ACM Transactions on Knowledge Discovery from Data*, ACM, v. 13, n. 2, p. 1–57, 2019.

TINARRAGE, R. et al. Empirical analysis of binding precedent efficiency in Brazilian Supreme Court via case classification. *Artificial Intelligence and Law*, 2025.

TRAAG, V. A.; WALTMAN, L.; ECK, N. J. van. From Louvain to Leiden: guaranteeing well-connected communities. *Scientific Reports*, v. 9, p. 5233, 2019.

VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems 30 (NIPS 2017)*. [S.l.: s.n.], 2017. p. 5998–6008. ArXiv:1706.03762.

VIANNA, D.; MOURA, E. S. de; SILVA, A. S. da. A topic discovery approach for unsupervised organization of legal document collections. *Artificial Intelligence and Law*, v. 32, n. 4, p. 1045–1074, 2024.

WEERDT, J. D. et al. Active trace clustering for improved process discovery. *IEEE Transactions on Knowledge and Data Engineering*, v. 25, n. 12, p. 2708–2720, 2013.

YERBURY, L. W. et al. On the use of relative validity indices for comparing clustering approaches. *ACM Transactions on Knowledge Discovery from Data*, v. 19, n. 8, p. 1–53, 2025.

ZARATIANA, U. et al. GLiNER2: schema-driven multi-task learning for structured information extraction. In: *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Suzhou, China: Association for Computational Linguistics, 2025. p. 130–140. Preprint: arXiv:2507.18546. Disponível em: <https://aclanthology.org/2025.emnlp-demos.10/>. Acesso em: 4 ago. 2026.

APÊNDICE A — Definições das medidas e convenções terminológicas

Convenções terminológicas

Resumo da convenção fixada na seção 3.1: em português, *processo* designa ao mesmo tempo o caso administrativo e o objeto da disciplina de *mineração de processos*. Para evitar a ambiguidade, este trabalho fixa: **processo administrativo** é o caso individual; **tipo de processo** é o agrupamento emergente; **mineração de processos** é a disciplina. *Trace* é traduzido por **traço**, e *event log* por **registros de atividades**. Dos três alfabetos de traço, **ação por unidade** é o alfabeto não projetado, em que cada estado é o par ação@unidade e que carrega ambos os eixos. Quanto ao segundo alfabeto, distingue-se **roteamento** — o alfabeto de traço, isto é, a representação modelada — de **tramitação**, o movimento administrativo propriamente dito a que a norma se refere. **Procedimento**, o terceiro, conserva apenas a sequência de ações, abstraída do organograma. Por fim, **ação** é o tipo de andamento registrado pelo sistema, e **atividade** é a ocorrência individual de uma ação em um processo administrativo.

Glossário das medidas

Tabela 22: Medidas utilizadas neste trabalho.

medida	categoria	melhor	definição
top-1	a jusante	↑	Parcela dos passos retidos em que a primeira predição do modelo é o verdadeiro estado seguinte.
top-3	a jusante	↑	Parcela dos passos retidos em que o verdadeiro estado seguinte está entre as três primeiras predições do modelo.
top-1 (common set)	a jusante	↑	top-1 recalculado apenas sobre os processos que todo agrupamento avalia, removendo o confundimento de cobertura. Nas tabelas: "t-1 comum".
successor baseline	linha de base	↑	Consulta ao sucessor mais frequente dentro do grupo. Piso para 'o modelo aprendeu alguma coisa'.
global model	controle	↑	Uma única cadeia de Markov de terceira ordem treinada sobre o corpus agregado. Responde 'um único modelo se sairia igualmente bem?'.
delta-star	a jusante	↑	O estimando: o escore da partição real menos o escore de seu controle embaralhado de forma equivalente (mesmo número de grupos, mesma distribuição de tamanhos, mesma população, com a pertença permutada). É positivo somente se a partição carrega sinal sobre o processo além da sua forma. Calculado por família de modelo, de modo que a comparação é termo a termo. delta_star_adjusted subtrai adicionalmente a linha de base global sob ambas as partições, cancelando o artefato de ponderação que global_baseline_residual reporta. É um CRITÉRIO DE ADMISSÃO, não uma ordenação: delta-star cresce com o número de famílias, porque especializar compensa mais quando as famílias são pequenas, e o controle preserva a forma mas não o que a própria granularidade compra. Nunca ordene partições de granularidade diferente por ele – use selection_score para isso; comparações em k pareado permanecem válidas.
global baseline residual	controle	↓	O modelo global agregado pontuado sobre os mesmos passos retidos sob a partição real e sob a embaralhada. Deve ser ~0 por construção; um valor diferente de zero significa que a ponderação por n_traces está produzindo efeito, e o desequilíbrio entre famílias deve ser reportado ao lado de delta-star.
shuffled partition	controle	↑	Mesma contagem de grupos, mesmos tamanhos, mesma população, com a pertença permutada. Piso para 'a partição é real?'. Isoladamente é o ganho gratuito de particionar, não um resultado; sua distância até o braço real é o delta-star.
gain vs global	a jusante	↑	Acurácia por grupo menos a acurácia da linha de base sobre os mesmos passos retidos. Medido dentro de um único alfabeto contra uma linha de base que enfrenta o mesmo vocabulário, de modo que é a única grandeza comparável entre representações. Ainda contém o ganho que qualquer partição da mesma distribuição de tamanhos obtém de graça, porque ajustar por família reduz o alfabeto de cada modelo — reporte-o ao lado do delta-star, nunca em seu lugar.
suffix distance	fidelidade	↓	Damerau-Levenshtein normalizado entre o sufixo que o modelo gera a partir de um meio-prefixo e o sufixo real. A razão de comprimento indica se um modelo vence por parar cedo demais.
suffix distance, constrained	fidelidade	↓	A mesma medida sob decodificação restrita, em que o autômato de fluxo filtra todo candidato. Emitida apenas para alfabetos cujos estados carregam uma ação; em um alfabeto de roteamento não há regra de ciclo de vida a impor.
flow validity	fidelidade	↑	Parcela dos passos gerados (e dos traços gerados inteiramente legais) que o autômato de ciclo de vida do processo permite. O par _real é a mesma medida sobre os registros de atividades observados, que é o teto.
unit_recall	cobertura	↑	Fração das unidades visitadas por um processo real que o caminho gerado também visita. Nas tabelas: "revocação de unidades".
unit_precision	cobertura	↑	Fração das unidades no caminho gerado que os processos reais de fato visitam.
visits_matched_frac	cobertura	↑	Fração das visitas de um processo real correspondidas pelo caminho gerado. Capta a cobertura no nível do passo, não apenas quais unidades.
transition_support	cobertura	↑	Número médio de ocorrências de cada transição gerada por membro do grupo. Conta ocorrências, não membros distintos, de modo que pode exceder 1 e não é uma proporção. A variante _min é o elo mais fraco do caminho.
transitions_unseen	fidelidade	↓	Transições do caminho gerado que não ocorrem em nenhum traço retido amostrado do grupo, contra uma amostra de

APÊNDICE B — Tabelas complementares

As tabelas a seguir complementam o audit trail do capítulo 4 sem repetir os mesmos artefatos já apresentados no corpo do texto. A grade completa — as catorze partições avaliadas por família de modelo e alfabeto, 84 linhas por alfabeto — sustenta a contagem de células declarada no capítulo 4.

Tabela 23: Grade completa de resultados, alfabeto de ação por unidade.

agrupamento	família	grupos	top-1	revocação	precisão	inéditas
exp-anon-hcoarse/hdbscan	transformer	33	0,725	0,685	0,711	2,808
exp-anon-hcoarse/hdbscan	lstm	33	0,715	0,681	0,691	2,876
exp-anon-hcoarse/hdbscan	gru	33	0,726	0,669	0,699	3,372
exp-anon-hcoarse/hdbscan	markov	33	0,720	0,620	0,710	3,604
exp-anon-hcoarse/hdbscan	dfg	33	0,571	0,603	0,710	5,043
exp-anon-hcoarse/hdbscan	gnn	33	0,619	0,634	0,700	5,930
exp-anon-kelbow/kmeans	transformer	55	0,711	0,727	0,757	2,620
exp-anon-kelbow/kmeans	gru	55	0,716	0,716	0,742	2,922
exp-anon-kelbow/kmeans	lstm	55	0,703	0,730	0,735	3,229
exp-anon-kelbow/kmeans	dfg	55	0,588	0,655	0,760	2,236
exp-anon-kelbow/kmeans	markov	55	0,712	0,678	0,772	3,369
exp-anon-kelbow/kmeans	gnn	55	0,624	0,662	0,777	4,193
exp-anon-ksil/kmeans	transformer	49	0,709	0,735	0,745	2,482
exp-anon-ksil/kmeans	gru	49	0,712	0,706	0,750	2,446
exp-anon-ksil/kmeans	lstm	49	0,702	0,716	0,750	3,512
exp-anon-ksil/kmeans	markov	49	0,709	0,667	0,748	3,362
exp-anon-ksil/kmeans	dfg	49	0,581	0,677	0,761	2,646
exp-anon-ksil/kmeans	gnn	49	0,619	0,670	0,776	4,680
exp-anon-lres/leiden	transformer	78	0,707	0,763	0,807	2,540
exp-anon-lres/leiden	dfg	78	0,610	0,712	0,810	2,048
exp-anon-lres/leiden	gru	78	0,711	0,743	0,801	2,882
exp-anon-lres/leiden	lstm	78	0,700	0,744	0,801	3,870
exp-anon-lres/leiden	gnn	78	0,634	0,701	0,817	3,670
exp-anon-lres/leiden	markov	78	0,708	0,726	0,792	4,820
exp-anon/hdbscan	gru	54	0,716	0,725	0,771	1,816
exp-anon/hdbscan	transformer	54	0,715	0,735	0,762	2,107
exp-anon/hdbscan	lstm	54	0,704	0,721	0,750	2,946
exp-anon/hdbscan	dfg	54	0,585	0,666	0,784	2,496
exp-anon/hdbscan	markov	54	0,714	0,668	0,785	3,295
exp-anon/hdbscan	gnn	54	0,624	0,661	0,795	3,930
exp-anon/kmeans	gru	52	0,716	0,722	0,762	2,189
exp-anon/kmeans	transformer	52	0,711	0,722	0,749	2,263
exp-anon/kmeans	lstm	52	0,706	0,729	0,744	3,255
exp-anon/kmeans	dfg	52	0,586	0,678	0,773	2,617
exp-anon/kmeans	markov	52	0,714	0,664	0,762	3,450
exp-anon/kmeans	gnn	52	0,624	0,669	0,770	4,421

agrupamento	família	grupos	top-1	revocação	precisão	inéditas
exp-anon/leiden	transformer	55	0,718	0,724	0,757	2,279
exp-anon/leiden	gru	55	0,719	0,728	0,769	2,703
exp-anon/leiden	dfg	55	0,593	0,683	0,786	2,041
exp-anon/leiden	lstm	55	0,710	0,705	0,773	2,826
exp-anon/leiden	markov	55	0,716	0,680	0,771	4,316
exp-anon/leiden	gnn	55	0,630	0,656	0,774	4,392
exp-raw-hcoarse/hdbscan	transformer	36	0,718	0,676	0,712	1,791
exp-raw-hcoarse/hdbscan	lstm	36	0,711	0,689	0,722	2,274
exp-raw-hcoarse/hdbscan	dfg	36	0,572	0,621	0,718	2,442
exp-raw-hcoarse/hdbscan	gru	36	0,719	0,677	0,708	3,823
exp-raw-hcoarse/hdbscan	markov	36	0,714	0,625	0,719	3,601
exp-raw-hcoarse/hdbscan	gnn	36	0,616	0,638	0,714	4,054
exp-raw-kelbow/kmeans	transformer	57	0,708	0,734	0,798	1,748
exp-raw-kelbow/kmeans	lstm	57	0,698	0,734	0,800	2,366
exp-raw-kelbow/kmeans	dfg	57	0,592	0,699	0,809	2,376
exp-raw-kelbow/kmeans	markov	57	0,708	0,706	0,793	3,556
exp-raw-kelbow/kmeans	gru	57	0,710	0,741	0,773	4,509
exp-raw-kelbow/kmeans	gnn	57	0,624	0,703	0,804	5,277
exp-raw-ksil/kmeans	lstm	50	0,700	0,730	0,761	2,361
exp-raw-ksil/kmeans	transformer	50	0,706	0,729	0,769	2,508
exp-raw-ksil/kmeans	gru	50	0,710	0,712	0,753	3,173
exp-raw-ksil/kmeans	markov	50	0,710	0,665	0,758	3,535
exp-raw-ksil/kmeans	dfg	50	0,589	0,686	0,769	3,949
exp-raw-ksil/kmeans	gnn	50	0,622	0,695	0,778	4,928
exp-raw-lres/leiden	transformer	78	0,709	0,743	0,788	2,224
exp-raw-lres/leiden	lstm	78	0,702	0,749	0,796	3,365
exp-raw-lres/leiden	dfg	78	0,609	0,711	0,802	2,709
exp-raw-lres/leiden	gru	78	0,712	0,742	0,791	3,950
exp-raw-lres/leiden	markov	78	0,711	0,706	0,780	3,949
exp-raw-lres/leiden	gnn	78	0,633	0,707	0,791	3,751
exp-raw/hdbscan	transformer	56	0,712	0,717	0,773	1,986
exp-raw/hdbscan	lstm	56	0,707	0,709	0,764	2,764
exp-raw/hdbscan	gru	56	0,715	0,715	0,772	3,184
exp-raw/hdbscan	dfg	56	0,587	0,669	0,779	2,418
exp-raw/hdbscan	markov	56	0,712	0,665	0,769	3,902
exp-raw/hdbscan	gnn	56	0,627	0,680	0,768	4,220
exp-raw/kmeans	transformer	52	0,709	0,745	0,753	1,694
exp-raw/kmeans	lstm	52	0,700	0,745	0,757	2,612
exp-raw/kmeans	gru	52	0,711	0,709	0,751	2,856
exp-raw/kmeans	gnn	52	0,623	0,710	0,764	3,831
exp-raw/kmeans	dfg	52	0,588	0,686	0,770	3,435
exp-raw/kmeans	markov	52	0,709	0,666	0,748	4,217
exp-raw/leiden	transformer	59	0,717	0,713	0,763	1,530
exp-raw/leiden	gru	59	0,720	0,711	0,760	2,648
exp-raw/leiden	lstm	59	0,711	0,713	0,776	3,137

agrupamento	família	grupos	top-1	revocação	precisão	inéditas
exp-raw/leiden	dfg	59	0,595	0,694	0,773	2,698
exp-raw/leiden	markov	59	0,716	0,655	0,756	4,220
exp-raw/leiden	gnn	59	0,631	0,667	0,777	3,763

Tabela 24: Grade completa de resultados, alfabeto de roteamento.

agrupamento	família	grupos	top-1	revocação	precisão	inéditas
exp-anon-hcoarse/hdbscan	gru	28	0,706	0,665	0,750	0,178
exp-anon-hcoarse/hdbscan	markov	28	0,698	0,646	0,739	0,159
exp-anon-hcoarse/hdbscan	lstm	28	0,687	0,666	0,743	0,279
exp-anon-hcoarse/hdbscan	transformer	28	0,713	0,670	0,733	1,018
exp-anon-hcoarse/hdbscan	gnn	28	0,466	0,650	0,702	0,450
exp-anon-hcoarse/hdbscan	dfg	28	0,439	0,634	0,722	0,541
exp-anon-kelbow/kmeans	markov	43	0,695	0,684	0,780	0,427
exp-anon-kelbow/kmeans	transformer	43	0,707	0,712	0,790	0,581
exp-anon-kelbow/kmeans	gru	43	0,700	0,706	0,788	0,570
exp-anon-kelbow/kmeans	lstm	43	0,685	0,710	0,780	0,583
exp-anon-kelbow/kmeans	dfg	43	0,459	0,677	0,771	0,474
exp-anon-kelbow/kmeans	gnn	43	0,476	0,684	0,760	0,688
exp-anon-ksil/kmeans	markov	39	0,696	0,681	0,763	0,386
exp-anon-ksil/kmeans	gru	39	0,699	0,702	0,789	0,569
exp-anon-ksil/kmeans	transformer	39	0,706	0,709	0,764	0,753
exp-anon-ksil/kmeans	lstm	39	0,687	0,707	0,771	0,719
exp-anon-ksil/kmeans	dfg	39	0,454	0,679	0,772	0,663
exp-anon-ksil/kmeans	gnn	39	0,473	0,694	0,753	0,783
exp-anon-lres/leiden	transformer	57	0,718	0,766	0,808	0,406
exp-anon-lres/leiden	gru	57	0,716	0,774	0,824	0,522
exp-anon-lres/leiden	markov	57	0,707	0,737	0,814	0,509
exp-anon-lres/leiden	lstm	57	0,702	0,761	0,819	0,764
exp-anon-lres/leiden	dfg	57	0,483	0,738	0,808	0,417
exp-anon-lres/leiden	gnn	57	0,497	0,731	0,803	0,796
exp-anon/hdbscan	gru	41	0,699	0,707	0,801	0,318
exp-anon/hdbscan	markov	41	0,694	0,686	0,796	0,425
exp-anon/hdbscan	transformer	41	0,711	0,720	0,781	0,665
exp-anon/hdbscan	lstm	41	0,683	0,703	0,786	0,819
exp-anon/hdbscan	gnn	41	0,476	0,703	0,770	0,585
exp-anon/hdbscan	dfg	41	0,458	0,690	0,775	0,812
exp-anon/kmeans	gru	42	0,702	0,712	0,773	0,344
exp-anon/kmeans	transformer	42	0,704	0,721	0,761	0,439
exp-anon/kmeans	markov	42	0,695	0,679	0,773	0,420
exp-anon/kmeans	lstm	42	0,686	0,715	0,772	0,706
exp-anon/kmeans	dfg	42	0,458	0,683	0,770	0,415
exp-anon/kmeans	gnn	42	0,475	0,700	0,757	0,647
exp-anon/leiden	gru	43	0,709	0,735	0,795	0,289

agrupamento	família	grupos	top-1	revocação	precisão	inéditas
exp-anon/leiden	markov	43	0,704	0,708	0,799	0,322
exp-anon/leiden	transformer	43	0,716	0,731	0,790	0,443
exp-anon/leiden	lstm	43	0,690	0,727	0,784	0,893
exp-anon/leiden	dfg	43	0,463	0,702	0,777	0,513
exp-anon/leiden	gnn	43	0,483	0,707	0,765	0,714
exp-raw-hcoarse/hdbscan	markov	30	0,697	0,674	0,761	0,264
exp-raw-hcoarse/hdbscan	transformer	30	0,713	0,651	0,741	0,297
exp-raw-hcoarse/hdbscan	lstm	30	0,694	0,665	0,752	0,295
exp-raw-hcoarse/hdbscan	gru	30	0,706	0,682	0,752	0,379
exp-raw-hcoarse/hdbscan	gnn	30	0,466	0,699	0,713	0,457
exp-raw-hcoarse/hdbscan	dfg	30	0,445	0,665	0,729	0,396
exp-raw-kelbow/kmeans	markov	43	0,700	0,716	0,823	0,124
exp-raw-kelbow/kmeans	transformer	43	0,715	0,738	0,806	0,279
exp-raw-kelbow/kmeans	gru	43	0,708	0,748	0,824	0,344
exp-raw-kelbow/kmeans	lstm	43	0,694	0,725	0,812	0,579
exp-raw-kelbow/kmeans	dfg	43	0,466	0,712	0,782	0,300
exp-raw-kelbow/kmeans	gnn	43	0,481	0,730	0,781	0,746
exp-raw-ksil/kmeans	markov	39	0,696	0,683	0,791	0,262
exp-raw-ksil/kmeans	gru	39	0,705	0,725	0,791	0,491
exp-raw-ksil/kmeans	lstm	39	0,692	0,723	0,790	0,540
exp-raw-ksil/kmeans	transformer	39	0,709	0,721	0,785	0,735
exp-raw-ksil/kmeans	dfg	39	0,458	0,718	0,773	0,672
exp-raw-ksil/kmeans	gnn	39	0,475	0,719	0,744	0,908
exp-raw-lres/leiden	gru	58	0,711	0,765	0,815	0,278
exp-raw-lres/leiden	transformer	58	0,716	0,746	0,800	0,392
exp-raw-lres/leiden	markov	58	0,703	0,717	0,813	0,360
exp-raw-lres/leiden	lstm	58	0,700	0,750	0,818	0,431
exp-raw-lres/leiden	dfg	58	0,484	0,732	0,789	0,337
exp-raw-lres/leiden	gnn	58	0,492	0,730	0,774	0,750
exp-raw/hdbscan	markov	43	0,691	0,691	0,813	0,160
exp-raw/hdbscan	gru	43	0,693	0,727	0,807	0,378
exp-raw/hdbscan	transformer	43	0,700	0,708	0,792	0,429
exp-raw/hdbscan	lstm	43	0,679	0,723	0,811	0,565
exp-raw/hdbscan	dfg	43	0,458	0,695	0,783	0,597
exp-raw/hdbscan	gnn	43	0,472	0,712	0,763	0,999
exp-raw/kmeans	markov	41	0,698	0,704	0,770	0,257
exp-raw/kmeans	gru	41	0,702	0,736	0,769	0,403
exp-raw/kmeans	lstm	41	0,688	0,733	0,773	0,380
exp-raw/kmeans	transformer	41	0,709	0,719	0,758	0,399
exp-raw/kmeans	dfg	41	0,459	0,710	0,740	0,565
exp-raw/kmeans	gnn	41	0,474	0,717	0,720	0,792
exp-raw/leiden	markov	42	0,704	0,695	0,798	0,106
exp-raw/leiden	gru	42	0,710	0,729	0,789	0,189
exp-raw/leiden	lstm	42	0,693	0,719	0,796	0,275
exp-raw/leiden	transformer	42	0,721	0,720	0,778	0,399

agrupamento	família	grupos	top-1	revocação	precisão	inéditas
exp-raw/leiden	dfg	42	0,466	0,696	0,773	0,228
exp-raw/leiden	gnn	42	0,484	0,675	0,752	0,707

Tabela 25: Grade completa de resultados, alfabeto de ação.

agrupamento	família	grupos	top-1	inéditas
exp-anon-hcoarse/hdbscan	markov	33	0,732	1,548
exp-anon-hcoarse/hdbscan	dfg	33	0,641	0,570
exp-anon-hcoarse/hdbscan	gnn	33	0,642	2,151
exp-anon-hcoarse/hdbscan	gru	33	0,756	3,644
exp-anon-hcoarse/hdbscan	lstm	33	0,756	3,203
exp-anon-hcoarse/hdbscan	transformer	33	0,752	2,766
exp-anon-kelbow/kmeans	markov	55	0,730	1,674
exp-anon-kelbow/kmeans	dfg	55	0,644	0,653
exp-anon-kelbow/kmeans	gnn	55	0,644	2,156
exp-anon-kelbow/kmeans	gru	55	0,754	3,105
exp-anon-kelbow/kmeans	lstm	55	0,754	2,417
exp-anon-kelbow/kmeans	transformer	55	0,750	2,134
exp-anon-ksil/kmeans	markov	49	0,731	1,421
exp-anon-ksil/kmeans	dfg	49	0,640	0,636
exp-anon-ksil/kmeans	gnn	49	0,642	1,949
exp-anon-ksil/kmeans	gru	49	0,753	2,537
exp-anon-ksil/kmeans	lstm	49	0,751	2,153
exp-anon-ksil/kmeans	transformer	49	0,750	1,838
exp-anon-lres/leiden	markov	78	0,735	1,944
exp-anon-lres/leiden	dfg	78	0,648	0,819
exp-anon-lres/leiden	gnn	78	0,649	2,586
exp-anon-lres/leiden	gru	78	0,754	3,145
exp-anon-lres/leiden	lstm	78	0,754	2,693
exp-anon-lres/leiden	transformer	78	0,751	2,730
exp-anon/hdbscan	markov	54	0,732	2,432
exp-anon/hdbscan	dfg	54	0,643	0,712
exp-anon/hdbscan	gnn	54	0,644	1,895
exp-anon/hdbscan	gru	54	0,756	2,904
exp-anon/hdbscan	lstm	54	0,755	3,003
exp-anon/hdbscan	transformer	54	0,752	1,727
exp-anon/kmeans	markov	52	0,732	1,708
exp-anon/kmeans	dfg	52	0,644	0,670
exp-anon/kmeans	gnn	52	0,644	2,355
exp-anon/kmeans	gru	52	0,755	2,841
exp-anon/kmeans	lstm	52	0,755	2,453
exp-anon/kmeans	transformer	52	0,753	2,163
exp-anon/leiden	markov	55	0,735	1,708
exp-anon/leiden	dfg	55	0,646	0,739

agrupamento	família	grupos	top-1	inéditas
exp-anon/leiden	gnn	55	0,647	1,691
exp-anon/leiden	gru	55	0,757	3,681
exp-anon/leiden	lstm	55	0,759	2,528
exp-anon/leiden	transformer	55	0,753	2,572
exp-raw-hcoarse/hdbscan	markov	36	0,731	2,710
exp-raw-hcoarse/hdbscan	dfg	36	0,640	0,613
exp-raw-hcoarse/hdbscan	gnn	36	0,639	2,458
exp-raw-hcoarse/hdbscan	gru	36	0,754	2,433
exp-raw-hcoarse/hdbscan	lstm	36	0,751	5,013
exp-raw-hcoarse/hdbscan	transformer	36	0,749	5,787
exp-raw-kelbow/kmeans	markov	57	0,730	2,271
exp-raw-kelbow/kmeans	dfg	57	0,642	0,892
exp-raw-kelbow/kmeans	gnn	57	0,643	2,003
exp-raw-kelbow/kmeans	gru	57	0,753	3,211
exp-raw-kelbow/kmeans	lstm	57	0,753	2,723
exp-raw-kelbow/kmeans	transformer	57	0,750	2,007
exp-raw-ksil/kmeans	markov	50	0,733	2,392
exp-raw-ksil/kmeans	dfg	50	0,643	0,739
exp-raw-ksil/kmeans	gnn	50	0,643	2,133
exp-raw-ksil/kmeans	gru	50	0,754	2,498
exp-raw-ksil/kmeans	lstm	50	0,753	2,800
exp-raw-ksil/kmeans	transformer	50	0,750	1,784
exp-raw-lres/leiden	markov	78	0,734	1,846
exp-raw-lres/leiden	dfg	78	0,649	0,942
exp-raw-lres/leiden	gnn	78	0,649	2,716
exp-raw-lres/leiden	gru	78	0,753	2,673
exp-raw-lres/leiden	lstm	78	0,752	3,221
exp-raw-lres/leiden	transformer	78	0,751	3,269
exp-raw/hdbscan	markov	56	0,736	2,342
exp-raw/hdbscan	dfg	56	0,648	0,724
exp-raw/hdbscan	gnn	56	0,648	2,359
exp-raw/hdbscan	gru	56	0,756	3,359
exp-raw/hdbscan	lstm	56	0,754	5,039
exp-raw/hdbscan	transformer	56	0,751	4,886
exp-raw/kmeans	markov	52	0,731	2,196
exp-raw/kmeans	dfg	52	0,642	0,862
exp-raw/kmeans	gnn	52	0,641	2,285
exp-raw/kmeans	gru	52	0,753	3,086
exp-raw/kmeans	lstm	52	0,751	2,466
exp-raw/kmeans	transformer	52	0,749	2,067
exp-raw/leiden	markov	59	0,735	2,236
exp-raw/leiden	dfg	59	0,645	0,663
exp-raw/leiden	gnn	59	0,646	1,911
exp-raw/leiden	gru	59	0,754	2,821
exp-raw/leiden	lstm	59	0,753	2,728

agrupamento	família	grupos	top-1	inéditas
exp-raw/leiden	transformer	59	0,751	2,245

ANEXO A — Termo de Ciência e Responsabilidade para o Tratamento dos Dados Pessoais (SEAD-PI)

Documento institucional que autoriza o acesso e o tratamento dos dados utilizados nesta pesquisa, firmado entre a Secretaria de Administração do Estado do Piauí, na condição de controladora, e o autor, na condição de servidor e pesquisador (PIAUÍ. Secretaria de Administração do Estado do Piauí, 2026). É reproduzido na íntegra, com tarja sobre os identificadores pessoais — número de CPF e matrícula —, cuja supressão não altera nenhuma das cláusulas.

As cláusulas que condicionam este trabalho são as seguintes.

> 2.1. O objeto é a concessão de acesso e o tratamento de dados constantes de processos do Sistema Eletrônico de Informações - SEI, nascidos e movimentados na SEAD-PI no período de janeiro a dezembro de 2025, para fins acadêmicos e para a realização de estudos e pesquisas [. . .]
>
> 4.4.1. A divulgação acadêmica (nacional ou internacional) limitar-se-á a: nomes de clusters, exemplos de processos genéricos/sintéticos, métricas agregadas e código-base sem segredos, sempre anonimizados e previamente aprovados pela SEAD-PI como camada adicional de controle.
>
> 5.1. A metodologia incluirá etapa de pseudonimização e/ou anonimização dos dados pessoais, de forma automatizada sempre que identificáveis, antes das fases de clusterização e vetorização.
>
> 5.2. O grafo inicial de exploração poderá conter dados não anonimizados, cuja etapa integra o tratamento sob responsabilidade da Controladora, restrita ao ambiente seguro, não constituindo uso acadêmico autônomo.
>
> 7.2. A base de dados/grafo derivado de dados públicos será de titularidade da Secretaria de Administração do Estado do Piauí, com licença de uso acadêmico ao servidor, de acordo com as diretrizes deste Termo de Responsabilidade.

A cláusula 5.1 é a origem do requisito metodológico descrito na seção 3.5: a anonimização não é uma escolha de projeto, e sim uma condição do instrumento que autoriza o estudo — razão pela qual o seu custo em utilidade é medido na seção 4.6 em vez de presumido. A cláusula 4.4.1 submete esta própria divulgação à aprovação prévia da controladora. A cláusula 7.2 delimita o que pode ser disponibilizado: a metodologia e o código-base são de titularidade do autor (cláusula 7.1), ao passo que a base derivada é da Secretaria.

TERMO DE CIÊNCIA E RESPONSABILIDADE PARA O TRATAMENTO DOS DADOS PESSOAIS - SEAD/PI

1. PARTES E PAPÉIS

CONTROLADORA: Secretaria de Administração do Estado do Piauí (SEAD-PI), inscrita no CNPJ sob o nº 06.553.481/0003-00, com sede no Centro Administrativo, Avenida Pedro Freitas, Bloco I, Bairro São Pedro, CEP 64018-900, Teresina/PI, neste ato representada por seu Secretário de Estado de Administração, SAMUEL PONTES DO NASCIMENTO, matrícula nº [redacted]

SERVIDOR: Gabriel Feitosa Melo Coelho, analista de dados da SEAD-PI, CPF nº [redacted] discente do curso de Engenharia de Software do ICEV – Instituto de Ensino Superior.

2. OBJETO E FINALIDADE

2.1. O objeto é a concessão de acesso e o tratamento de dados constantes de processos do Sistema Eletrônico de Informações - SEI, nascidos e movimentados na SEAD-PI no período de janeiro a dezembro de 2025, para fins acadêmicos e para a realização de estudos e pesquisas, com vistas à geração de artefatos técnicos de apoio à melhoria da transformação digital dos processos da SEAD-PI, onde serão executadas as seguintes atividades:
a) mapeamento de processos (unidades, ações e tramitações);
b) análise e treinamento de modelos de IA sobre processos do SEI.

2.2. Qualquer uso para finalidade diversa é vedado e dependerá de nova autorização.

3. TERMOS E DEFINIÇÕES

3.1. Para o presente Termo considera-se:
a) dado pessoal: informação relacionada a pessoa natural identificada ou identificável;

b) dado pessoal sensível: dado pessoal sobre origem racial ou étnica, convicção religiosa, opinião política, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou biométrico, quando vinculado a uma pessoa natural;

c) proteção de dados pessoais, nos termos do inciso LXXIX do art. 5º da Constituição Federal: ações que visam proteger direitos e liberdades fundamentais das pessoas naturais, entre eles a sua privacidade, inclusive em meios digitais;

d) privacidade: direito à inviolabilidade da intimidade, da vida privada, da honra e da imagem das pessoas, nos termos do inciso X do art. 5º da Constituição Federal;

e) anonimização: é a utilização de meios técnicos razoáveis que possibilita a perda da associação, direta ou indireta, do dado pessoal a um indivíduo;

f) pseudoanonimização: é o tratamento por meio do qual um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo, senão pelo uso de informação adicional mantida separadamente pelo controlador em ambiente controlado e seguro;

g) grafo inicial: base de dados estruturada em modelo de grafo, implementada em tecnologia orientada a grafos (por exemplo, Neo4j), composta por nós e relacionamentos que representam as entidades dos processos do SEI (processos, documentos, unidades, ações, tramitações e respectivos agentes) e as conexões entre elas, destinada à etapa exploratória de análise, podendo, nessa fase, conter dados pessoais ainda não anonimizados;

h) código-base: conjunto de instruções, algoritmos, scripts e configurações, legíveis por pessoa natural, que implementam a metodologia de coleta, tratamento, pseudonimização/anonimização, modelagem e análise dos dados, excluídos quaisquer segredos, credenciais, chaves de acesso ou informações sigilosas;

i) artefatos: quaisquer produtos resultantes do tratamento e da pesquisa, tais como relatórios técnicos, códigos, scripts, modelos treinados, bases de dados, grafos, documentação técnica e visualizações, entregues à Controladora nos termos deste Termo;

j) clusters: agrupamentos de processos ou documentos formados automaticamente por técnicas de aprendizado de máquina não supervisionado, a partir da similaridade de suas características (andamentos, ações e conteúdo vetorizado), cujos rótulos são derivados de informações representativas do próprio agrupamento (centroide), a exemplo de "Solicitação de Férias";

k) incidente de segurança: qualquer evento adverso confirmado, relacionado à violação das propriedades de confidencialidade, integridade, disponibilidade e autenticidade da segurança de dados pessoais;

l) medidas de segurança: medidas técnicas e/ou administrativas adotadas para proteger os dados pessoais de acessos não autorizados e de situações acidentais ou ilícitas de destruição, perda, alteração, comunicação ou difusão;

m) tratamento de dados: toda operação realizada com dados pessoais, como as que se referem a coleta, produção, recepção, classificação, utilização, acesso, reprodução, transmissão, distribuição, processamento, arquivamento, armazenamento, eliminação, avaliação ou controle da informação, modificação, comunicação, transferência, difusão ou extração;

n) banco de dados: conjunto estruturado de dados pessoais, estabelecido em um ou em vários locais, em suporte eletrônico ou físico;

o) titular: pessoa natural a quem se referem os dados pessoais que são objeto de tratamento;

p) controlador: pessoa natural ou jurídica, de direito público ou privado, a quem competem as decisões referentes ao tratamento de dados pessoais;

4. DAS RESPONSABILIDADES

4.1. O tratamento de dados pessoais observará as diretrizes nacionais, estaduais e as normativas da SEAD-PI, e ocorrerá, integralmente, em ambiente computacional do Estado do Piauí, sem que os dados deixem as dependências tecnológicas estaduais, com stack completamente local (computação e modelos), utilizando modelos de código aberto executados localmente.

4.1.1. A Controladora fornecerá credenciais e a metodologia de acesso aos dados, nos termos da sua Política de Controle de Acesso.

4.1.2. Deverão ser implementadas a anonimização e pseudoanonimização dos dados pessoais pelo servidor, para o cumprimento do objeto deste Termo, podendo ser comprovada, a qualquer tempo, a anonimização/pseudoanomização aplicadas.

4.2. Será observado o Guia sobre o Tratamento de dados pessoais para fins acadêmicos e para a realização de estudos e pesquisas.

4.3. Serão observadas as boas práticas e uso ético da Inteligência Artificial Generativa, não podendo ser compartilhados com estes recursos quaisquer dados pessoais ou sigilosos vinculados aos processos SEI.

4.4. Qualquer produção acadêmica do pesquisador (TCC e eventual publicação), destinado ou não para divulgação pública, utilizará, exclusivamente, dados anonimizados (art. 12 da LGPD), que não se qualificam como dados pessoais, razão pela qual o tratamento para fins acadêmicos não recai sobre dados pessoais identificáveis.

4.4.1. A divulgação acadêmica (nacional ou internacional) limitar-se-á a: nomes de clusters, exemplos de processos genéricos/sintéticos, métricas agregadas e código-base sem segredos, sempre anonimizados e previamente aprovados pela SEAD-PI como camada adicional de controle.

4.5. É vedada, em qualquer circunstância:
a) a transferência dos dados pessoais a terceiros;
b) o uso de serviços de nuvem ou de APIs externas que impliquem saída de dados;
c) a cópia de dados pessoais para fora do ambiente autorizado, ressalvado o estritamente necessário à execução do projeto e mediante controle;
d) a revelação dos dados pessoais e sigilosos tratados.

5. DA PSEUDONIMIZAÇÃO E ANONIMIZAÇÃO DOS DADOS PESSOAIS

5.1. A metodologia incluirá etapa de pseudonimização e/ou anonimização dos dados pessoais, de forma automatizada sempre que identificáveis, antes das fases de clusterização e vetorização.

5.2. O grafo inicial de exploração poderá conter dados não anonimizados, cuja etapa integra o tratamento sob responsabilidade da Controladora, restrita ao ambiente seguro, não constituindo uso acadêmico autônomo.

6. DOS ENTREGÁVEIS

6.1. O servidor que ora subscreve o presente Termo entregará, exclusivamente, à SEAD-PI:
a) o banco de dados de grafos com processos e metadados mapeados;
b) relatório técnico de insights;
c) o código-base (sem segredos/credenciais).

6.2. A Secretaria revisará os entregáveis, solicitando retificações e confirmação formal de entrega.

7. TITULARIDADE E LICENCIAMENTO (PROPRIEDADE INTELECTUAL)

7.1. A metodologia/código será de titularidade do servidor, com licença perpétua e gratuita à Secretaria de Administração do Estado do Piauí.

7.2. A base de dados/grafo derivado de dados públicos será de titularidade da Secretaria de Administração do Estado do Piauí, com licença de uso acadêmico ao servidor, de acordo com as diretrizes deste Termo de Responsabilidade.

8. DISPOSIÇÕES FINAIS

8.1. Os incidentes de segurança envolvendo dados pessoais deverão ser comunicados internamente, observando-se o setor, o canal, o prazo e a forma definidos na normativa de gestão de incidentes de segurança da SEAD-PI.

8.2. A inobservância do presente Termo de Responsabilidade, bem como das leis federais e estaduais sobre proteção de dados pessoais, segurança da informação e do tratamento dos dados e informações sigilosas, ensejará em possíveis sanções cíveis, administrativas e penais, notadamente a tutela penal dos sistemas de informações e dos bancos de dados da Administração Pública, em especial o art. 153, § 1º-A, art. 154-A, art. 313-A, art. 313-B e art. 325, conforme previsto na Lei do Servidor Público Estadual, resguardado o devido processo administrativo.

8.3. Este Termo vigorará até dezembro de 2027. Encerrado o prazo de vigência deste Termo ou a finalidade do mesmo, os dados pessoais tratados deverão ser entregues à SEAD-PI e eliminados do banco de dados do responsável, com a devida comprovação da eliminação.

SAMUEL PONTES DO NASCIMEN[redacted]

Assinado de forma digital por SAMUEL PONTES DO [redacted]

Dados: 2026.07.10 22:09:11 -03'00'

CONTROLADORA

SERVIDOR